



Fakultät Druck und Medien
Studiengang Medieninformatik

Bachelor Thesis
zur Erlangung des akademischen Grades Bachelor of Science

Evaluierung von Systemen zur Speicherung und Bereitstellung von Binärdaten im Kontext von Web Services

Gamze Isik

19. Juni 2023

Matrikelnummer: 39307

Bearbeitungszeitraum: 20. März - **19. Juni 2023**

Betreuer

Erstbetreuer: Prof. Martin Goik
Hochschule der Medien

Zweitbetreuer: Thomas Maier
Leomedia GmbH

Erklärung

Hiermit erkläre ich, dass ich die vorliegende Arbeit selbständig angefertigt habe. Es wurden nur die in der Arbeit ausdrücklich benannten Quellen und Hilfsmittel benutzt. Wörtlich oder sinngemäß übernommenes Gedankengut habe ich (mit Ausnahme dieser Erklärung) als solches kenntlich gemacht.

Ort, Datum

Unterschrift

Zusammenfassung

Das Ziel der vorliegenden Arbeit ist die Evaluierung eines Systems zur Speicherung und Bereitstellung von Binärdaten im Kontext von Web Services. Diese Binärdaten sollen Kunden des Produkts leoticket der Leomedia GmbH zur Verfügung gestellt werden. Dabei werden Anforderungen wie Performance, Verfügbarkeit, Sicherheit und eine Möglichkeit für Integrationen durch APIs in Software Produkten am Beispiel des Produkts leoticket der Leomedia GmbH dargestellt. Durch die Realisierung eines Prototyps anhand ausgewählter Speicherlösungen werden die Binärdaten durch sichere, zeitlich begrenzte URL's bereitgestellt. Folgende Fragen werden gestellt: Welches Speichersystem ist im Hinblick auf Kosten, Performance und Verfügbarkeit für die Persistenz von Binärdaten besonders geeignet? Wie können Daten durch sichere, zeitlich begrenzte URL's bereitgestellt werden? Verschiedene Speichersysteme werden verglichen und anhand von Kostenkalkulationen bewertet. Durch die Auswertung des Vergleichs werden der Prototyp implementiert und Messungen auf Testdaten durchgeführt. Die Kosten-, und Performance Analyse ergibt, dass die Speicherklassen Standard-IA von AWS sowie die Nearline von GC die Anforderungen des Produkts leoticket der Leomedia GmbH weitestgehend erfüllen. Sie bieten eine hochverfügbare, kostengünstige und leistungsfähige Speicherung an, die durch verschiedene Einstellungen wie die SSE-KMS Sicherheit bietet und durch SDKs eine gute Integration in eigene Anwendungen verspricht. Durch die bereitgestellten Methoden für die Generierung von signierten, zeitlich begrenzten URLs können die Daten an die Ticketkäufer von leoticket ohne weitere Authentifizierung als Kundensicht zur Verfügung gestellt werden. Diese Feststellung und Empfehlung dient dem Umstieg auf neue Speicherlösungen mit höherer Performance und Sicherheit bei akzeptablen Kosten.

Abstract

The aim of this thesis is to evaluate a system for storing and providing binary data in the context of web services. Requirements such as performance, availability, security, and API integration being defined. By implementing a prototype based on the selected storage solution, binary data is provided by means of secure, time-limited URLs. The following questions are addressed: Which storage system is particularly suitable for persisting binary data in terms of cost, performance, and availability? How can data be provided through secure, time-limited URLs? Different storage systems are being compared and evaluated providing cost estimations. By evaluating the comparison, the prototype is implemented and measurements are taken on test data. The results suggest a switch to a new storage solution thereby improving both performance and security at acceptable costs.

Inhaltsverzeichnis

Akronyme	4
Abbildungsverzeichnis	5
Tabellenverzeichnis	6
1 Einleitung	7
1.1 Problemstellung und Motivation	7
1.2 Zieldefinition und Vorgehensweise	9
2 Speichersysteme	10
2.1 Arten von Speichersystemen	11
2.1.1 File Storage	11
2.1.2 Block Storage	13
2.1.3 Object Storage	14
2.2 Aktuelle Speichertechnologien im Markt	15
2.2.1 Eigenschaften	15
2.2.1.1 Sichere Speicherung	16
2.2.1.2 Hochverfügbarkeit	22
2.2.1.3 Kosten	24
2.2.1.4 Performance	28
2.2.1.5 API Anbindung	31
2.2.2 Bereitstellung der Dateien	34
2.3 Auswahl des Speichersystems	36
2.3.1 Kostenanalyse	36
2.3.2 Entscheidungsfindung	39
3 Prototypische Umsetzung	42
3.1 Überblick und Vorgehensweise	42
3.2 Eingesetzte Technologien	43
3.3 Speicherung von Binärdaten	44
3.4 Bereitstellung der Binärdaten	47
3.5 Messung der Performance	49
3.5.1 Messungsergebnisse	51
3.6 Zusammenfassung der Implementierung	54
4 Ergebnisse dieser Arbeit	55
4.1 Beschreibung und Funktionalität des Prototyps	55
4.2 Zusammenfassung der Ergebnisse	57
4.2.1 Kalkulationsergebnisse	57
4.2.2 Messergebnisse	59

5	Diskussion	61
5.1	Analyse und Interpretation der Ergebnisse	61
5.2	Bewertung des Prototyps	63
6	Fazit	65
6.1	Beantwortung der Forschungsfrage	65
6.2	Potenzielle Anwendung des Prototyps	66
7	Danksagung	67
8	Literaturverzeichnis	68
9	Anhang	70
9.1	Repositories	70
9.1.1	Github Link	70
9.1.2	Dokumentation	70
9.1.3	Code Snippets	70

Akronyme

Abb.	Abbildung
ADC	Application Default Credentials
Anm.	Anmerkung
API	Application Programming Interface
AWS	Amazon Web Services
CLI	Command Line Interface
CRR	Cross Region Replication
CRUD	Create, Read, Update, Delete
dt.	deutsch
engl.	englisch
FUSE	Filesystem in Userspace
gb	Gigabytes
GC	Google Cloud
GCP	Google Cloud Platform
GCS	Google Cloud Storage
HTML	Hypertext Markup Language
HTTP	Hypertext Transfer Protocol
IAM	Identity and Access Management
JSON	Javascript Object Notation
kB	Kilobytes
REST	Representational State Transfer
S3	Simple Storage Service
SDK	Software Development Kit
SRR	Same Region Replication
SSE	Server-Side Encryption
SSE-C	Server-Side Encryption with Customer-Provided Keys
SSE-KMS	Server-Side Encryption with AWS Key Management Service
SSE-S3	Server-Side Encryption with S3 Managed Keys
tb	Terabytes
URL	Uniform Resource Locator
USA	United States of America, dt. Vereinigte Staaten von Amerika
XML	Extensible Markup Language

Abbildungsverzeichnis

2.1.1 File Storage: Aufbau des Hierarchiesystems, ^{redHat-storage} https://www.redhat.com/en/topics/data-storage/file-block-object-storage	11
2.2.1 GCS Dauer des Uploads, ^{gcp-blog} https://cloud.google.com/blog/products/gcp/optimizing-your-cloud-storage-performance-google-cloud-performance-atlas/	30
4.2.1 Upload Zeit der verschiedenen Speicherklassen	59
4.2.2 Download Zeit der verschiedenen Speicherklassen	60

Tabellenverzeichnis

2.2.1 Einstellungen für Object Ownership, ^{aws-iam-s3} https://docs.aws.amazon.com/de_de/AmazonS3/latest/userguide//access-control-overview.html	18
2.2.2 Verfügbarkeit der Speicherklassen gemäß Google Cloud Storage SLA, ^{gcp-sla} https://cloud.google.com/storage/sla	23
2.2.3 Übersicht der Kosten der AWS S3 Speicherklassen	24
2.2.4 Vergleich der Kosten von Google Cloud Storage Speicherklassen	26
2.2.5 Unterstützte Programmiersprachen von AWS SDK, ^{aws-sdk} https://docs.aws.amazon.com/AmazonS3/latest/userguide/UsingAWSSDK.html	31
2.3.1 Übersicht der einzelnen Kosten der Datenspeicherung in Amazon S3	37
2.3.2 Übersicht der einzelnen Kosten der Datenspeicherung in GC Storage	38
4.2.1 Zusammenfassung der Gesamtkosten für AWS S3 pro Speicherklasse	57
4.2.2 Zusammenfassung der Gesamtkosten für GC Storage pro Speicherklasse	58

1 Einleitung

Das folgende Kapitel dient der Einführung in die Problemstellung, Motivation sowie Ziele und Vorgehensweisen der vorliegenden Arbeit.

1.1 Problemstellung und Motivation

Die steigende Menge an Daten im Kontext von Web Services, die in verschiedenen Anwendungen generiert werden, stellt eine große Herausforderung dar. Diese Bachelorarbeit richtet sich auf die Herausforderung einer Full-Service-Ticketing Software „leoticket“, die vom Unternehmen Leomedia GmbH entwickelt wird. Leomedia GmbH ist ein Unternehmen, das Software für Medienunternehmen wie Zeitungsverlage, Radiosender, Veranstalter, Künstler und Kulturvereine entwickelt.¹ Leoticket ist eines der vielen Produkte von Leomedia, dass Services wie Online-Kartenvorverkäufe, Abendkassen, den Einlass bei der Veranstaltung, Statistiken, Abrechnungen und die Planung der Veranstaltung realisiert.²

Die erfassten Daten umfassen verschiedene Arten von Dokumenten, wie beispielsweise PDF-Dateien, insbesondere Tickets und Rechnungen, die aus dem Kaufprozess über die leoticket Plattform resultieren. Dabei ist es von großer Bedeutung, dass diese Daten von leoticket-Kunden und Leomedia sicher, zuverlässig und schnell gespeichert und abgerufen werden können. Vor diesem Hintergrund stellen sich Fragen nach der Auswahl eines geeigneten Speichersystems, welches die Performance, Verfügbarkeit, Sicherheitsanforderungen und die Möglichkeit der Integration in Software-Produkten wie leoticket erfüllt. Zudem müssen Mechanismen bereitgestellt werden, um den Zugriff der Ticketbesitzer auf die Daten durch sichere, zeitlich begrenzte URL's zu beschränken.

Die Herausforderung von leoticket betrifft die Speicherung und Bereitstellung von Daten wie Tickets und Rechnungen an die Ticketkäufer. Ein Galera Cluster ist eine Multi-Master-Replikationslösung für relationale Datenbanken. Es basiert auf dem Konzept der synchronen Replikation, bei dem mehrere Knoten zu einem Cluster miteinander verbunden. Im Rahmen des Replikationsprozesses werden Daten synchronisiert, wodurch sich die Leistung bei Anfragen verringert, da das Datenbanksystem durch die Ausführung des Replikations- bzw. Synchronisierungsjobs beansprucht wird. Dabei erreicht der Arbeitsspeicher seine Kapazitätsgrenze von 200 GB. Die Hauptaufgaben der Datenbank umfassen beispielsweise die Durchführung von JOINS.

Eine weitere Herausforderung ist die Bereitstellung der Dateien über Email Anhänge. Anhänge dürfen eine bestimmte Speichergröße nicht überschreiten. Wenn Ticketkäufer mehrere Tickets in einer Bestellung tätigen, dann müssen diese über Email Anhänge bereitgestellt werden.

Leomedia plant eine Neugestaltung der leoticket-Anwendung, bei der sie sich von der Galera Cluster Technologie lösen möchten. In dieser Untersuchung werden keine relationalen Datenbanken

¹[leomedia-web](#)
²[leomedia-web](#)
¹Leomedia: Bachelor- und Master-Themen, [9].
²ebd.

berücksichtigt. Relationale Datenbanksysteme basieren auf einem festen Schema, das vorab definiert werden muss. Dies kann problematisch sein, wenn die Struktur der erfassten Daten des Produkts leoticket häufig geändert oder erweitert werden muss. NoSQL-Datenbanken bieten in dieser Hinsicht oft mehr Flexibilität, da sie schemalos oder mit flexiblen Schemas arbeiten. Weitere Gründe sind die Skalierbarkeit, Komplexität und der Speicherplatzbedarf. Es ist wichtig anzumerken, dass diese Gründe nicht bedeuten, dass relationale Datenbanksysteme grundsätzlich ausgeschlossen werden sollten. Sie sind nach wie vor eine bewährte und weit verbreitete Lösung für viele Anwendungen. Die Entscheidung, ein relationales Datenbanksystem auszuschließen, hängt von den spezifischen Anforderungen und Herausforderungen ab, die vorab für diese Arbeit definiert wurden.

1.2 Zieldefinition und Vorgehensweise

Das Ziel dieser Arbeit besteht darin, anhand der Anforderungen von leoticket eine geeignete Speicherlösung zu empfehlen und die Realisierung eines Prototypen basierend auf den ausgewählten Cloud-Providern zu erstellen. Der Prototyp soll die Bereitstellung vordefinierter Daten durch sichere und zeitlich begrenzte URLs ermöglichen.

Dabei werden folgende Fragen gestellt:

- Welches Speichersystem ist im Hinblick auf Kosten, Performance und Verfügbarkeit für die Persistenz von Daten besonders geeignet?
- Wie können diese Daten durch sichere, zeitlich begrenzte URL's bereitgestellt werden?

Zur Beantwortung werden verschiedene Arten von Speichersystemen untersucht. Dabei erfolgt eine Analyse aktuell verfügbarer Speichertechnologien hinsichtlich ihrer nicht-funktionalen Eigenschaften wie Sicherheit, Verfügbarkeit, Performance und Kosten, die im Zusammenhang mit den verwendeten Technologien entstehen können. Aus funktionaler Sicht wird auch die Möglichkeit der Integration des Speichersystems in Software Produkten und die sichere Bereitstellung der erfassten Dateien betrachtet. Cloud-Provider werden miteinander verglichen und Kosten-, und Performance-Kalkulationen durchgeführt. Die Ergebnisse werden anschließend ausgewertet und interpretiert, um eine geeignete Speicherlösung zu empfehlen.

Der Prototyp wird auf Basis der von Cloud Providern angebotenen ausgewählten Technologien und Empfehlung implementiert. Nach der Durchführung von Messungen zur Performance auf Testdaten erfolgt eine Zusammenfassung der Implementierung.

Zum Abschluss werden die Ergebnisse präsentiert, interpretiert und eine Bewertung des Prototyps vorgenommen. Die am Anfang gestellten Fragen der Arbeit werden beantwortet und potenzielle Anwendungen des Prototyps aufgelistet.

2 Speichersysteme

Speichersysteme sind eine entscheidende Komponente der IT Infrastruktur eines Unternehmens. In der heutigen Zeit kann von Speichersystemen kaum abgesehen werden, da Big Data mehr an Wichtigkeit gewinnt. Big Data ist ein Begriff, der sich auf große Mengen an strukturierten, semi-strukturierten und unstrukturierten Daten bezieht, die mit hoher Geschwindigkeit und in unterschiedlichen Formaten generiert, gespeichert und analysiert werden. Es umfasst Daten, die aus verschiedenen Quellen stammen, wie beispielsweise soziale Medien, Sensoren, Maschinenprotokolle, Transaktionsdaten, Textdokumente. Laut ^{oracle-bigdata} Oracle fallen die bekannten drei V-Begriffe Variety, Volume und Velocity darunter, die im Artikel „Was versteht man unter Big Data?“ erwähnt werden. Sie bieten eine Möglichkeit, große Mengen an Daten zu speichern und zu verwalten, um den Zugriff und die Nutzung zu erleichtern. Es gibt eine Vielzahl an Speichersystemen, die für verschiedene Zwecke konzipiert sind. Durch die große Auswahl in der IT und die stetig anwachsende Innovation stellt sich die Frage, welche Speichersysteme sich für bestimmte Zwecke eignen. Die Wahl des richtigen Speichersystems hängt von den Anforderungen des Unternehmens ab, beispielsweise der Art der zu speichernden Daten, dem benötigten Zugriff und die Skalierbarkeit. Eine gründliche Analyse der Anforderungen und Kosten ist entscheidend, um die beste Lösung zu finden, die den Bedürfnissen des Unternehmens entspricht.

Im folgenden Kapitel werden die unterschiedlichen Typen von Speichersystemen vorgestellt, wobei der Fokus auf den drei Speicherarten File-, Object- und Block Storage liegt. Im Anschluss daran erfolgt ein Vergleich von zwei Cloud-Providern in Bezug auf sichere Speicherung, Hochverfügbarkeit, Performance, Kosten, Integration in Software-Produkten sowie der Dateibereitstellung. Auf Basis dieser Kriterien wird eine Entscheidung darüber getroffen, welcher Provider den Bedürfnissen von leoticket am besten entspricht. Hierbei fließen die Kosten- und Performance-Analysen mit in die Entscheidung ein.

2.1 Arten von Speichersystemen

Die heutige IT-Landschaft bietet eine Vielzahl von Speichersystemen, die je nach Bedarf und Anforderungen ausgewählt werden können. Neben den traditionellen Speichermedien wie File Storage gibt es andere Arten, die in der Cloud oder als lokale Lösungen bereitgestellt werden können. Dazu gehören unter anderem Object Storage und Block Storage. Jede dieser Speicherarten hat ihre spezifischen Vor- und Nachteile und ist für bestimmte Anwendungsfälle besser geeignet.

2.1.1 File Storage

File Storage, auch dateiebenen- oder dateibasierter Storage genannt¹, ist eine Speicherlösung bei der Dateien auf einem Dateisystem gespeichert werden.

Dieses System wird auch als hierarchischer Storage bezeichnet und gilt als das älteste und am weitesten verbreitete Datenspeichersystem für Direct und Network-Attached Storage. Dateisysteme organisieren Daten in hierarchischen Ordnern und Unterverzeichnissen, beispielsweise auf einem Computer. Dateien werden in der Regel auf einem Server oder einer Festplatte gespeichert und können von mehreren Benutzern gleichzeitig gelesen und geschrieben werden. Hierbei werden die Informationen in einzelnen Verzeichnissen abgelegt und können über den entsprechenden Pfad aufgerufen werden. Um dies zu ermöglichen, werden Metadaten genutzt, die dem System den Standort der Dateien mitteilen, vgl. [redHat-storage RedHat](https://www.redhat.com/en/topics/data-storage/file-block-object-storage).

In der folgenden Abbildung wird die hierarchische Struktur des Dateispeichers visualisiert.




Abbildung 2.1.1: File Storage: Aufbau des Hierarchiesystems, [redHat-storage https://www.redhat.com/en/topics/data-storage/file-block-object-storage](https://www.redhat.com/en/topics/data-storage/file-block-object-storage)

File Storage wird häufig in Unternehmen und Organisationen eingesetzt, um gemeinsame Dateiserver bereitzustellen oder Daten in Cloud-Speicherdiensten wie Dropbox oder Google Drive zu speichern. Auch wenn es von Betriebssystemen und Anwendungen gut unterstützt wird, kann die Performance und Skalierbarkeit von File Storage bei sehr großen Dateisystemen beeinträchtigt werden, was insbesondere bei stark frequentierten Anwendungen oder bei der Verarbeitung großer Datenmengen zum Problem werden kann.

Mit zunehmenden Datenvolumen erfordert das Skalieren von Dateispeichern das Hinzufügen neuer Hardwaregeräte oder den Austausch vorhandener Geräte durch solche

¹[redHat-storage](https://www.redhat.com/en/topics/data-storage/file-block-object-storage)
¹RedHat: File storage, block storage, or object storage? (2018), [12].

mit höherer Kapazität. Dies kann im Laufe der Zeit teuer werden. „As data volumes expand, scaling file storage requires [...]“, (~~Wahlman~~^{nx-fileScala}: Data Storage: Exploring File, Block, and Object Storage (2022), [\[19\]](#), Übersetzung des Autors)

Laut Wahlmann (~~2022~~^{nx-fileScala}, Übersetzung des Autors) wird die Datenspeicherung bei zu vielen Daten nicht nur teuer, sondern auch unhandlich und zeitaufwändig. Der schnelle und einfache Zugriff auf jede Datei wird schwierig, wenn viele Dateien in Tausenden von Verzeichnissen auf Hunderten von Speichergrößen gespeichert werden.

2.1.2 Block Storage

Block Storage in der lokalen Umgebung bezieht sich auf die Speicherung von Daten in Form von Speicherblöcken auf physischen Geräten. Im Gegensatz dazu erfordert File Storage ein Dateisystem, das die Organisation, Verwaltung und den Zugriff auf die gespeicherten Daten ermöglicht. Speichermedien ohne ein Dateisystem, wie eine leere Festplatte oder ein nicht formatiertes Laufwerk, können als Block Storage betrachtet werden, da sie die Daten in Blöcken speichern können, ohne eine spezifische Dateiorganisation zu haben.

Block Storage in der Cloud speichert Dateien auf Cloud-basierten Speicherumgebungen. Die Cloud-basierte Block Storage stellt dabei einzelne Speicherblöcke als Service bereit. Dies geschieht in Form von virtuellen Festplatten oder Blockvolumes, die über die Cloud-Infrastruktur angeboten werden. Bei der Verwendung von Block Storage in der Cloud können Benutzer Speicherblöcke in beliebiger Größe erstellen und diese an virtuelle Maschinen oder andere Ressourcen in der Cloud anhängen. Der Zugriff auf die Speicherblöcke erfolgt über ein Blockprotokoll wie iSCSI oder Fibre Channel.

Wenn auf Block Storage gespeicherte Daten abgerufen werden, verwendet das Server-Betriebssystem die eindeutige Adresse, um die Blöcke wieder zusammenzufügen und so die Datei zu erstellen. Der Vorteil besteht darin, dass das System nicht durch Verzeichnisse und Dateihierarchien navigieren muss, um auf die Datenblöcke zuzugreifen. Dadurch werden Effizienzen erzielt, da der Abruf von Daten schneller erfolgen kann, vgl. ^{ibm-storage}IBM: What is object storage?, [7].

Typische Anwendungsbereiche des Block Storage sind Datenbanken, Virtualisierungsumgebungen und Anwendungen für Big Data-Analysen. Speicherung von strukturierten Daten wie Datenbanken, Virtuelle Maschinen und Betriebssysteme eignen sich besonders bei der Verwendung von Block Storage. Sie ermöglichen eine hohe Flexibilität, da Benutzer die Größe und Konfiguration der Speicherblöcke anpassen können, um den individuellen Anforderungen gerecht zu werden. Darüber hinaus bieten sie eine hohe Skalierbarkeit, da zusätzliche Speicherblöcke bei Bedarf hinzugefügt werden können, um den wachsenden Speicherbedarf zu bewältigen. Diese Art von Daten erfordert schnellen und direkten Zugriff auf bestimmte Bereiche des Speichers und muss häufig in Echtzeit ausgeführt werden. Block Storage eignet sich daher am besten für Anwendungen mit hohen Anforderungen an die Leistung und niedriger Latenzzeit.

2.1.3 Object Storage

Object Storage hat sich als Speichertechnologie in den letzten Jahren immer stärker etabliert und wird von vielen Unternehmen als Alternative zu traditionellen Speicherlösungen wie Block- oder File Storage angesehen. Die ersten Object Storage Systeme wurden bereits in den 1990er Jahren entwickelt, aber erst mit dem Aufkommen von Big Data, IoT und der Cloud-Nutzung hat es einen breiteren Einsatz gefunden. Heute bieten viele Cloud Provider wie Amazon Web Services (AWS) und Google Cloud Platform (GCP) Object Storage als einen ihrer Haupt-Cloud-Services an.

Object Storage ist für den Umgang mit großen Datenvolumen und unstrukturierten Daten entwickelt. Sie speichert Daten als eigenständige Objekte, die aus Daten und Metadaten bestehen und einen eindeutigen Identifier (UID) haben, („Object storage (aka object-based storage) is a type of data storage used to [...]“, ^{dataCore-OS} Ivanov: File Storage vs. Object Storage: Understanding Differences, Applications and Benefits, What is Object Storage? (2020), [8], Übersetzung des Autors).

Im Gegensatz zu hierarchischen Systemen wie beim File Storage ist das Speichersystem flach strukturiert. Durch die einfache API Anbindung kann es mit vorhandenen Anwendungen integriert werden. Nutzer können detaillierte Informationen wie beispielsweise Erstellerangaben, Schlüsselwörter sowie Sicherheit- und Datenschutzrichtlinien hinterlegen. Diese Daten bezeichnet man als Metadaten. Laut ^{nx-fileScala} Wahlman, 2022 ist Skalierbarkeit der Hauptvorteil, da bei der Speicherung von Petabyte und Exabyte alle Objekte in einem Namespace abgelegt werden. Selbst wenn dieser Namespace auf Hunderte von Hardwaregeräten und Standorten verteilt ist, können alle Objekte schnell abgerufen werden. Ein weiterer Vorteil von Objekt Storage beinhaltet die Fehlercodierung bzw. Fehlerkorrekturverfahren, im Englischen bekannt als „Erasure Coding“ und die Datenanalyse.

Auch Object Storage hat Nachteile. Laut ^{redHat-storage} RedHat muss das Objekt nach der Speicherung bei Veränderung komplett neu überschrieben werden. Sie sind für traditionelle Datenbanken nicht geeignet, da das Schreiben von Objekten Zeit beansprucht und man sich mit der API auseinandersetzen muss, vgl. ^{redHat-storage} RedHat.

Insgesamt bietet Object Storage eine skalierbare und flexible Methode zur Speicherung von unstrukturierten Daten. Organisationen sollten jedoch die Vor- und Nachteile von Object Storage im Kontext ihrer spezifischen Anwendungsfälle abwägen, um eine fundierte Entscheidung über die beste Speichermethode zu treffen.

Fazit

Aufgrund der Anforderungen von leoticket, Daten wie Rechnungen und Tickets zu speichern und abzurufen, erweist sich Object Storage als die geeignete Speicheroption. Da keine spezifischen Anforderungen hinsichtlich der Latenzzeit bestehen und auch keine Dateien im Petabyte- oder Exabyte-Bereich gespeichert werden müssen, scheidet die Block Storage-Variante aus. Viele Cloud-Anbieter stellen Methoden für Object Storage bereit, die Sicherheitsfunktionen, hohe Verfügbarkeit, gute Performance und eine Möglichkeit der Integration in Software-Produkten umfassen. Darüber hinaus ermöglichen Cloud Storage-Systeme die Bereitstellung von Dateien als Links. Die Skalierbarkeit ist ein weiterer entscheidender Faktor, der für die Wahl von Object Storage spricht.

2.2 Aktuelle Speichertechnologien im Markt

Die beiden bekanntesten Cloud-Anbieter Amazon Web Services (AWS) und Google Cloud Platform (GCP) bieten eine Vielzahl von Speicherlösungen an, die auf die Bedürfnisse von Unternehmen zugeschnitten sind.

In diesem Kapitel werden die aktuellen Speichertechnologien auf dem Markt untersucht, wobei der Fokus auf den Angeboten von AWS und GCP liegt. Um eine Vergleichsgrundlage zwischen AWS und GCP zu schaffen, werden die verschiedenen Aspekte wie sichere Speicherung, Hochverfügbarkeit, Leistung, Kosten, API Anbindung und die Bereitstellung der Dateien betrachtet. Dieses Vorgehen dient der Ermittlung der angebotenen Object Storage Speichersysteme der Cloud Provider, die am besten die genannten Anforderungen erfüllt.

AWS bietet eine Reihe von Speicheroptionen an, darunter Amazon S3 (Simple Storage Service). Amazon S3 ist ein Object Storage-Service, der für die Speicherung und den schnellen Abruf von unstrukturierten Daten wie Videos, Fotos und Dokumenten ausgelegt ist. GCP bietet ebenfalls eine Vielzahl von Speicherlösungen an, darunter Google Cloud Storage (GC Storage). Letztere ist ein Object Storage-Service, der ebenfalls für die Speicherung von unstrukturierten Daten wie Bildern, Videos und Dokumenten ausgelegt ist.

Insgesamt bieten AWS und GCP eine Vielzahl von Speicherlösungen an, die auf die Bedürfnisse von Unternehmen zugeschnitten sind. Organisationen sollten jedoch die Vor- und Nachteile jeder Speicherlösung abwägen, um die beste Lösung für ihre spezifischen Anforderungen zu finden.

2.2.1 Eigenschaften

Im vorliegenden Abschnitt werden Amazon S3 und GC Storage in Bezug auf verschiedene Kriterien untersucht. Die Auswahl der Kriterien erfolgt in Anlehnung an die spezifischen Anforderungen von leoticket. Dabei werden zunächst die Eigenschaften von Amazon S3 erläutert, gefolgt von einer Betrachtung von GC Storage. Ziel ist es, Funktionen und Angebote beider Cloud Provider zu untersuchen, die die Kriterien erfüllen und eine Entscheidungshilfe für leoticket zu bieten.

2.2.1.1 Sichere Speicherung

Viele Anbieter von Object Storage-Lösungen bieten integrierte Verschlüsselungsmöglichkeiten an, um sicherzustellen, dass Daten sowohl in Ruhe als auch in Bewegung geschützt sind. Dabei können unterschiedliche Verschlüsselungsmethoden zum Einsatz kommen. In Bezug auf die sichere Speicherung bieten sowohl AWS als auch GCP Optionen für die Verschlüsselung von Daten. Die Sicherheit der gespeicherten Daten ist von entscheidender Bedeutung, um die Vertraulichkeit der Daten zu gewährleisten und den Zugriff auf diese Daten einzuschränken.

Amazon S3

IAM (Identity and Access Management) ist ein wichtiger Bestandteil von AWS und ermöglicht Benutzer, Gruppen und Rollen zu erstellen, um den Zugriff auf S3 zu verwalten. Benutzern können individuelle Berechtigungen zugewiesen werden, während Gruppen und Rollen mehrere Benutzer mit denselben Berechtigungen zusammenfassen können. Auf S3-Buckets und Objekte kann eine granulare Zugriffssteuerung angewendet werden. Benutzer, Gruppen oder Rollen können so berechtigt werden, den Zugriff auf bestimmte Buckets und Objekte zu beschränken oder zu erlauben. "Beim Erteilen von Berechtigungen in Amazon S3 entscheiden Sie, wer die Berechtigungen erhält, für welche Amazon-S3-Ressourcen die Berechtigungen gelten und welche Aktionen zu diesen Ressourcen gestattet werden sollen." ^{aws-iam-s3} AWS: Security: Identity and Access Management, [2]

Eine weitere Sicherheitsfunktion von Amazon S3 ist die Datenverschlüsselung. S3 bietet eine Vielzahl von Verschlüsselungsoptionen für die serverseitige und clientseitige Verschlüsselung. Da die clientseitige Verschlüsselung für leoticket keine Anwendung findet, wird diese Methode nicht weiter in Betracht gezogen. Die clientseitige Verschlüsselung erfordert die Generierung und Kommunikation eines separaten Schlüssels für jeden Kunden, um auf die Dateien zugreifen zu können. Aus Gründen des Aufwands ist diese Vorgehensweise nicht praktikabel. Daher wird der Schwerpunkt auf die serverseitige Verschlüsselung gelegt. Es existieren drei Verschlüsselungsmethoden: die serverseitige Verschlüsselung mit Amazon S3-verwalteten Schlüsseln (SSE-S3), mit dem AWS Key-Management-Service-verwalteten Schlüsseln (SSE-KMS) und die vom Kunden verwalteten Schlüsseln (SSE-C). Durch diese Optionen haben Benutzer die Möglichkeit, die Verschlüsselung gemäß ihren individuellen Anforderungen anzupassen und somit die Datensicherheit zu gewährleisten.

Laut ^{aws-iam-s3} AWS nutzen Buckets standardmäßig die SSE-S3 Methode. Für die Verschlüsselung wird die 256-bit Advanced Encryption Standard (AES-256) verwendet. Seit dem 5. Januar 2023 sind alle neu erstellen Buckets auf SSE-S3 ausgelegt. Alle neuen Objekte sind beim Hochladen ohne weitere Zusatzkosten und kein Einbußen der Leistung automatisch verschlüsselt.

Die Serverseitige Verschlüsselung schützt die Daten während sie in S3 gespeichert sind oder sich aktiv oder in "Ruhe" befinden. Amazon S3 verschlüsselt jedes Objekt mit einem eindeutigen Schlüssel. Als zusätzliche Sicherheitsmaßnahme werden diese eindeutigen Schlüssel mit einem weiteren Schlüssel verschlüsselt, welches in regelmäßigen Abständen rotiert wird, vgl. ^{aws-iam-s3} ebd.

Amazon S3 bietet auch die SSE-KMS (Server-Side Encryption with AWS Key Management Service) als Option an. AWS-KMS ist ein Dienst, der ein Schlüsselverwaltungssystem zur Verfügung stellt. Es verschlüsselt die Objektdaten und speichert die S3-Prüfsumme, die sich in den Objektmetadaten befindet, in verschlüsselter Form. Die SSE-KMS kann über die AWS Management-Konsole oder die AWS KMS API verwaltet werden.

Bei der Verwendung von SSE-KMS stehen zwei Methoden zur Verfügung: die AWS-Managed-Key oder die Customer-Managed-Key. Diese unterstützen die sogenannte „envelope encryption“. Das bedeutet, dass die Schlüssel für die Daten mithilfe eines Master Keys verschlüsselt werden. Dies erleichtert die Verwaltung der Schlüssel.

Bei der Verwendung der AWS-Managed-Key-Variante wird automatisch ein Schlüssel generiert, sobald ein Objekt in einen Bucket hochgeladen wird. Dieser generierte Schlüssel wird dann für die Ver- und Entschlüsselung der Daten verwendet. Wenn jedoch ein eigener Schlüssel über KMS verwendet werden soll, muss zunächst ein symmetrischer Schlüssel vor der KMS-Konfiguration erstellt werden. Bei der Erstellung des Buckets kann dann der selbst erstellte Schlüssel angegeben werden. Die Verwendung von Customer-Managed-Keys bietet bestimmte Vorteile, die den Anforderungen von Leoticket entsprechen. Durch die Verwendung von selbst erstellten Schlüsseln wird mehr Flexibilität und Kontrolle gewährleistet. Diese Schlüssel können selbst erstellt, rotiert und deaktiviert werden. Zusätzlich können Zugriffskontrollen und Auditierung konfiguriert werden, um den Schutz der Daten zu gewährleisten.

Durch die Auswahl der SSE-KMS-Variante besteht die Möglichkeit, die S3 Bucket Key-Funktion zu aktivieren. Diese Funktion kann die Anfragekosten um bis zu 99 Prozent reduzieren, indem der Anfragenverkehr von Amazon S3 zu AWS KMS verringert wird. Durch die Aktivierung des S3 Bucket Keys werden eindeutige Datenschlüssel für die Objekte im Bucket generiert. Diese Bucket Keys werden für einen festgelegten Zeitraum verwendet, wodurch die Anfragen an Amazon S3 zur Durchführung von Verschlüsselungsoperationen auf AWS KMS reduziert werden.

Die letzte Option ist SSE-C (Server-Side Encryption with Customer-Provided Keys). Bei SSE-C stellt der Kunde seinen eigenen Schlüssel zur Verfügung. Im Gegensatz zu AWS KMS speichert Amazon S3 diesen Schlüssel nicht. Mit dem bereitgestellten Schlüssel übernimmt Amazon S3 die Datenverschlüsselung während des Schreibvorgangs sowie die Datenentschlüsselung beim Zugriff auf Objekte. Anschließend entfernt Amazon S3 den Schlüssel aus dem Speicher. Da Amazon S3 den Schlüssel nicht speichert, wird der zufällig generierte HMAC (Hash-based Message Authentication Code) des Verschlüsselungsschlüssels gespeichert, um zukünftige Anfragen zu validieren. „Note: Amazon S3 does not store the encryption key that you provide.“, ^{aws-sse-c} AWS: Using server-side encryption with customer-provided keys (SSE-C), [3].

Object Ownership ist eine weitere Sicherheitsfunktion von Amazon S3. Mit Object Ownership können Benutzer oder Gruppen die Eigentümerschaft von Objekten in S3-Buckets besitzen. Dies bedeutet, dass nur autorisierte Benutzer die Berechtigung haben, Objekte zu löschen oder zu ändern, was die Sicherheit der Daten erhöht. „S3 Object Ownership ist eine Einstellung auf Amazon-S3-Bucket-Ebene, mit der Sie Zugriffskontrolllisten (ACLs) deaktivieren und das Eigentum an jedem Objekt in Ihrem Bucket übernehmen können, [...]“, ^{aws-iam-s3} AWS: Security: Identity and Access Management, [2].

AWS empfiehlt die ACL (Access Control List) auf Bucket-Ebenen deaktiviert zu lassen. Alle Objekte eines Buckets gehört so dem Bucket Owner. Laut ^{aws-iam-s3} AWS verfügt Object Ownership über drei Einstellungen, mit denen man die Eigentümerschaft von Objekten steuern kann.

Einstellung	Gilt für	Auswirkung auf Object Ownership	Auswirkungen auf ACLs	Hochladen akzeptiert
Bucket-Eigentümer erzwingen(empfohlen)	Alle neuen und bestehenden Objekte	Bucket-Eigentümer besitzt jedes Objekt.	ACLs sind deaktiviert. Bucket-Eigentümer hat das volle Eigentum und die volle Kontrolle.	Uploads mit ACL mit vollem Zugriff des Bucket-Eigentümers oder Uploads, die keine ACL angeben
Bucket-Eigentümer bevorzugt	Neue Objekte	Wenn ein Objekt-Upload die bucket-owner-full-control vordefinierte ACL beinhaltet, gehört dem Bucket Eigentümer das Objekt. Objekte, die mit anderen ACLs hochgeladen wurden, gehören dem Schreibkonto	ACLs können aktualisiert werden und können Berechtigungen erteilen. Wenn ein Objekt-Upload die bucket-owner-full-control vordefinierte ACL enthält, hat der Bucket-Eigentümer Vollzugriff und der Objekt-Writer hat keinen Vollzugriff mehr.	Alle Uploads
Object-Writer (Standard)	Neue Objekte	Der Objekt-Writer besitzt das Objekt	ACLs können aktualisiert werden und können Berechtigungen erteilen. Der Objekt-Writer hat vollen Kontrollzugriff	Alle Uploads

Tabelle 2.2.1: Einstellungen für Object Ownership, ^{aws-iam-s3} https://docs.aws.amazon.com/de_de/AmazonS3/latest/userguide/access-control-overview.html

Laut ^{aws-iam-s3}AWS zeigt die obige Tabelle die Auswirkungen, die jede Einstellung für Object Ownership auf ACLs, Objekte, Objekteigentümer und Objekt-Uploads hat.

Logging ist ein weiterer Aspekt der Amazon S3-Sicherheit. S3 bietet Logging-Optionen, darunter Bucket Logging und Object-Level Logging, die es Benutzern ermöglichen, Zugriffe auf S3-Objekte aufzuzeichnen und zu überwachen. Diese Funktionen sind entscheidend, um Compliance Anforderungen zu erfüllen und verdächtige Aktivitäten zu erkennen. AWS bietet eine Vielzahl von Tools zur Überwachung der Amazon S3 Ressourcen. Darunter die Amazon CloudWatch Alarms, AWS CloudTrail Logs, Amazon S3 Access Logs und die AWS Trusted Advisor.

Google Cloud Storage

Mit Cloud IAM können ähnlich wie in AWS IAM auch rollenbasierte Zugriffsberechtigungen auf bestimmte Ressourcen beispielsweise für Bucket-, und Objektebene umgesetzt werden. Sowohl Rollen als Berechtigungen können in der ähnlichen Funktionsweise wie bei AWS erstellt und zugewiesen werden. GC IAM verwendet das Konzept von Rollen, um Berechtigungen zu definieren. Es bietet vordefinierte Rollen wie Besitzer, Bearbeiter und Viewer, die verschiedene Berechtigungen für bestimmte Ressourcen gewähren. AWS IAM verwendet ebenfalls Rollen, um Berechtigungen zu definieren. Es bietet vordefinierte Rollen wie Administratorzugriff und Lesezugriff. Es ist zu beachten, dass beide Dienste unterschiedliche Terminologien und Konzepte verwenden können, obwohl sie ähnliche Funktionen bieten.

Auch GC bietet eine Vielzahl an Sicherheitsfunktionen, um sicherzustellen, dass Daten in der Cloud sicher gespeichert und geschützt sind. Unter anderem die Datenverschlüsselung. GC bietet wie Amazon S3 die serverseitige Verschlüsselung an. Hier werden zwischen Google-managed Keys, Customer-managed encryption keys und die Customer-supplied encryption keys unterschieden. Google-managed encryption ist die Standard Verschlüsselungsoption von GC ähnlich wie die AWS SSE-S3. AWS und GC bieten ähnliche Funktionalitäten der Datenverschlüsselung an. Dies wäre die serverseitige Datenverschlüsselung, bevor die Daten auf die Festplatte geschrieben werden.

Die Standard Variante verwaltet für den Nutzer die Encryption Keys in ihrem eigenen Key Management System. Auch GC verwendet für die Verschlüsselung die AES-256 wie AWS. Als Nutzer muss man bei dieser Variante keine Einstellungen berücksichtigen. Daten werden automatisch beim Abruf verschlüsselt, vgl. ^{gcp-encrypt}Storage: Google-managed encryption keys, [17].

Wenn ein höheres Maß an Kontrolle über die Schlüssel gewünscht wird, steht die Option der Customer-Managed Encryption zur Verfügung, die mit der AWS SSE-KMS customer-managed-Funktion gleichwertig ist. Die Schlüssel werden durch den Cloud KMS (Cloud Key Management Service) erstellt und verwaltet. Der Benutzer speichert diese Schlüssel extern oder in einem HSM-Cluster (Hardware Security Module). Customer-Keys können entweder für einzelne Objekte verwendet werden oder es kann ein Standard-Key für einen Bucket erstellt werden. Ähnlich wie bei den Bucket Keys in AWS können die erstellten Schlüssel zur Verschlüsselung der Objektdaten, zur CRC32C-Prüfsumme des Objekts und für den MD5-Hash verwendet werden. Um zusätzlichen Schutz zu gewährleisten, stehen Service Agents zur Verfügung, auch bekannt als Service Accounts. Diesen Agenten können bestimmte Berechtigungen zugewiesen werden, um Zugriff auf den gewünschten Encryption Key zu erhalten und Objekte zu verschlüsseln.

Schließlich besteht auch die Möglichkeit der Verwendung von Customer-supplied Encryption Keys, wobei es sich in AWS um die SSE-C-Variante handelt. Als zusätzliche Sicherheitsebene zu Google-managed encryption keys können Nutzer ihren eigenen AES-256 Encryption Key bereitstellen, welches als Base64 encoded ist. Bei dieser Variante wird der Schlüssel nicht von GC gespeichert oder verwaltet. Genau wie bei AWS SSE-C müssen die Nutzer diese Schlüssel selber verwalten und speichern. Um zukünftige Requests zu validieren speichert GC einen kryptografischen Hash vom Schlüssel. Jedoch kann der Encryption Key nicht aus dem Hash regeneriert werden.

Darüber hinaus bietet GC auch Zugriffskontrolleinstellungen, mit denen Benutzer genau steuern können, wer auf Dateien in Buckets zugreifen kann. Der Zugriff kann sowohl auf Bucket- als auch auf Objektebene gesteuert werden, wobei Benutzern und Gruppen bestimmte Rollen zugewiesen werden können. Dabei wird zwischen „Uniform Access Control“ (UAC) und „Fine-grained Access Control“ (FGAC) unterschieden. UAC ermöglicht es, ähnlich wie bei der ACL auf Bucket-Ebene in AWS, den Zugriff auf einen gesamten Bucket in GC Storage auf der Ebene von Rollen zuzuweisen. Dabei können verschiedene vordefinierte Rollen wie „Leser“, „Schreiber“ oder „Besitzer“ verwendet werden, um festzulegen, welche Aktionen ein Benutzer auf dem Bucket ausführen darf. UAC stellt eine einfachere Methode zur Zugriffskontrolle dar, da die Zugriffsrechte auf Bucket-Ebene vergeben werden. Das bedeutet, dass alle Objekte des Buckets automatisch dieselben Zugriffsrechte erhalten.

FGAC hingegen ermöglicht es, die Zugriffskontrolle auf die Ebene von Objekten oder sogar auf Teile von Objekten herunter zu brechen. Das bedeutet, dass jeder Benutzer oder jede Gruppe individuelle Zugriffsrechte auf bestimmte Objekte oder Teile von Objekten haben kann. Mit FGAC können feingranulare Zugriffssteuerungen implementiert werden. Es ist eine mächtige Methode, aber auch komplexer und zeitaufwändiger zu implementieren als UAC. Beide Cloud Provider empfehlen die ACL auf Objekt-Ebene deaktiviert zu lassen und nur bei speziellen Fällen anzuwenden. Standardmäßig ist die ACL auf Bucket-Ebene eingestellt.

Für das Object Logging in GC Storage stehen verschiedene Methoden zur Verfügung. GC bietet die Möglichkeit, spezielle Logging-Buckets zu erstellen, in denen alle Zugriffsprotokolle für Objekte gespeichert werden. Auch können Storage-Bucket-Audit-Logs aktiviert werden, um detaillierte Informationen über die Aktivitäten in Buckets zu erhalten.

2.2.1.2 Hochverfügbarkeit

Amazon S3

Amazon S3 ist ein skalierbarer und hochverfügbarer Objekt Storage, der eine Verfügbarkeit von 99.99% garantiert. „Designed to provide 99.999999999% durability and 99.99% availability of objects over a given year.“, ^{aws-availability} AWS: Data Protection in Amazon S3, [1]

Dies wird durch die Verwendung von Multi-Availability Zone Architekturen erreicht, die eine automatische Replikation von Daten in verschiedenen physischen Standorten ermöglichen. Die Multi-Availability Zone Architektur von Amazon S3 basiert auf der Aufteilung von Daten in mehrere geografisch getrennte Verfügbarkeitszonen (AZs). Jede AZ besteht aus mehreren physischen Rechenzentren, die sich in einem geografisch getrennten Gebiet befinden. Jede AZ ist vollständig unabhängig und bietet eine hohe Redundanz und Verfügbarkeit. Wenn ein Benutzer ein Objekt in Amazon S3 hochlädt, wird es automatisch in mehrere AZs repliziert, um sicherzustellen, dass das Objekt auch bei Ausfällen in einer AZ weiterhin verfügbar ist. Im Falle eines Ausfalls einer AZ wird Amazon S3 automatisch die Anfragen auf eine andere AZ umleiten, um eine ununterbrochene Verfügbarkeit des Objekts sicherzustellen. Durch die Cross-Region Replikation (CRR) werden Daten automatisch in andere AWS-Regionen repliziert. Dadurch kann eine hohe Verfügbarkeit der Daten im Falle eines Ausfalls einer gesamten AWS-Region gewährleistet werden. Die Same-Region-Replikation (SRR) funktioniert, ähnlich wie die CRR, nur dass hier die Daten in einer einzelnen Region auf die verfügbaren AZs repliziert wird.

Zusätzlich zu Multi-Availability Zone Architekturen verwendet Amazon S3 auch Fehlerkorrektur- und Erkennungsmechanismen wie CRC-Prüfungen, um die Integrität von Daten sicherzustellen, damit die gespeicherten Daten stets korrekt sind.

Durch Aktivierung der Versionierung wird jeder Objektversion, die in einem S3-Bucket gespeichert ist, eine eindeutige Versions-ID zugewiesen. Wenn eine Objektversion versehentlich gelöscht oder überschrieben wird, kann die vorherige Version wiederhergestellt werden.

Um eine hohe Verfügbarkeit bereitzustellen, stellt S3 außerdem noch die S3-Transfer Acceleration zur Verfügung. Durch die Verwendung von Amazon S3-Transfer Acceleration können Benutzer die Übertragung großer Datenmengen beschleunigen, indem ein optimierter Netzwerkpfad genutzt wird. Dadurch kann die Verfügbarkeit der Daten verbessert werden, indem Verbindungsprobleme minimiert werden. Um die Leistung von S3 zu überwachen und auf mögliche Probleme reagieren zu können wird CloudWatch bereitgestellt. Auf diese Weise kann die Ausfallzeit minimiert und analysiert werden, zu welchen Zeitpunkten die Verfügbarkeit am geringsten ist.

Insgesamt bietet Amazon S3 eine hochverfügbare und zuverlässige Speicherlösung, die durch Multi-Availability Zone Architekturen und Fehlerkorrekturmechanismen eine Verfügbarkeit von 99,99% gewährleistet.

Google Cloud Storage

Laut ^{gcp-sla}Cloud: Cloud Storage Service Level Agreement (SLA), [4] wird die Verfügbarkeit als Service Level Agreement (SLA) angegeben, welches die garantierte Verfügbarkeit des Dienstes definiert. Gemäß dem aktuellen SLA von GC Storage beträgt die garantierte Verfügbarkeit für Multi-Regionale Speicher 99,95% und für Regionale Speicher 99,9%. Diese Zahlen geben an, dass GC Storage darauf ausgelegt ist, eine sehr hohe Verfügbarkeit zu gewährleisten. AWS bietet ähnliche Prozente an Verfügbarkeit an und unterscheidet sich kaum. Beide versprechen eine hohe Verfügbarkeit. In der folgenden Tabelle werden diese Werte nochmals belegt:

Cloud Service	Monthly Uptime Percentage
Standard storage class in a multi-region or dual-region location of Cloud Storage	$\geq 99.95\%$
Standard storage class in a regional location of Cloud Storage; Nearline, Coldline, or Archive storage class in a multi-region or dual-region location of Cloud Storage	$\geq 99.9\%$
Nearline, Coldline, or Archive storage class in a regional location of Cloud Storage; Durable Reduced Availability storage class in any location of Cloud Storage	$\geq 99.0\%$

Tabelle 2.2.2: Verfügbarkeit der Speicherklassen gemäß Google Cloud Storage SLA, ^{gcp-sla}<https://cloud.google.com/storage/sla>

Es ist jedoch zu beachten, dass die tatsächliche Verfügbarkeit von GC Storage und Amazon S3 von mehreren Faktoren abhängt, einschließlich der spezifischen Konfiguration, dem Datenzugriffsmuster, der Netzwerkverfügbarkeit und anderen betrieblichen Variablen. Es ist daher möglich, dass die tatsächliche Verfügbarkeit in der Praxis leicht von der garantierten Verfügbarkeit abweicht.

Auch Google Cloud Storage bietet die Multi-Region Storage wie die CRR von AWS an. Dies ermöglicht die Speicherung von Daten in mehreren Regionen weltweit. Dadurch werden die Daten redundant repliziert und bleiben auch im Falle eines Ausfalls einer Region verfügbar. Dieses Prinzip ähnelt dem von AWS, denn auch dort werden die Daten automatisch repliziert. Außerdem bietet GC genau wie AWS SRR die Single-Region Replikation an.

Ein weiterer Punkt ist die Monitoring und Fehlererkennung wie Stackdriver Monitoring, um die Leistung und Verfügbarkeit von GC Storage zu überwachen und auf potenzielle Probleme zu reagieren. Dies gleicht auch dem CRC von AWS.

Zuletzt bietet Object Versioning die Möglichkeit, Objektversionen beizubehalten. Dadurch können vorherige Versionen von Objekten wiederhergestellt werden, falls sie versehentlich gelöscht oder überschrieben werden. Diese Funktionalität entspricht der Objektversionierung von AWS.

2.2.1.3 Kosten

In diesem Abschnitt erfolgt eine Untersuchung der Kostenstruktur von Amazon S3 und GC Storage. Dabei werden die generellen Kostenfaktoren betrachtet, für die Cloud-Anbieter Gebühren erheben.

Amazon S3

Amazon S3 erhebt Gebühren für verschiedene Leistungsbereiche, darunter die Speicherung, Anfragen, Datenabrufe, Datenübertragung, Verwaltung, Analyse und Replikation. Die Speicherungsgebühr richtet sich nach der Objektgröße, der Speicherdauer innerhalb eines Monats und der gewählten Speicherkategorie. Es stehen verschiedene Speicherkategorien zur Verfügung, die für unterschiedliche Anwendungsfälle geeignet sind. Dies wären S3 Standard, S3 Intelligent-Tiering (IA), S3 Standard – Infrequent Access (IA), S3 One Zone – Infrequent Access (IA), S3 Glacier Instant Retrieval, S3 Glacier Flexible Retrieval (ehemals S3 Glacier) und S3 Glacier Deep Archive. In dieser Arbeit wird S3 Glacier nicht behandelt, da die Abrufzeiten der Objekte zu lange Zeit in Anspruch nehmen und den Anforderungen von leoticket nicht entspricht. Stattdessen werden die Speicherkategorien S3 Standard, S3 IA, S3 Standard - IA und S3 One Zone - IA näher untersucht. Zur Veranschaulichung werden die Preise in der folgenden Tabelle dargestellt:

	Standard	Intelligent Tiering	Standard-IA	One Zone-IA
Speicher/GB im Monat	0.023 EUR	0.023 EUR	0.013 EUR	0.010 EUR
PUT-,COPY-,POST-,LIST-Anforderungen (pro 1000)	0.0050 EUR	0.0050 EUR	0.0093 EUR	0.0093 EUR
GET-,SELECT und alle anderen Anforderungen (pro 1000)	0.00040 EUR	0.00040 EUR	0.00093 EUR	0.00093 EUR
Datenabrufe	–	–	0.00093 EUR	0.00093 EUR
Monitoring und Automation pro Objekt	–	0.0000023 EUR	–	–
Datenübertragung aus S3 in das Internet	0.084 EUR pro GB			

Tabelle 2.2.3: Übersicht der Kosten der AWS S3 Speicherkategorien

In der vorliegenden Tabelle sind die Standardpreise für verschiedene Speicherkategorien von Amazon S3 aufgeführt. Die Preise für PUT-, COPY-, POST- und LIST-Anforderungen basieren auf einer Staffelung von 1000 Anfragen, ähnlich wie bei GET-, SELECT- und anderen Anforderungen. Sowohl die Speicherkategorie Standard als auch Intelligent Tiering (IA) haben eine Speicherungsgebühr von 0,023 Euro und Anforderungsgebühren von 0,0050 Euro für POST-Anforderungen und 0,00040 Euro für GET-Anforderungen. Für die Speicherkategorien Standard-IA und OneZone-IA liegen die

Speicherungsgebühren bei 0,013 Euro bzw. 0,010 Euro. Die Anforderungsgebühren betragen 0,0093 Euro für POST-Anforderungen und 0,00093 Euro für GET-Anforderungen. Zusätzlich erheben beide Speicherklassen eine Datenabrufgebühr von 0,00093 Euro. Es fallen auch Datenübertragungsgebühren von Amazon S3 zum Internet in Höhe von 0,084 Euro pro GB für alle Speicherklassen an. Es sei darauf hingewiesen, dass nur die IA-Speicherklasse zusätzliche Gebühren in Höhe von 0,084 Euro pro Objekt für die Verwaltung von Objekten erhebt.

Auch für die Replikation fallen in Amazon S3 Gebühren an. Bei der Replikation von Daten fallen zusätzlich zu den Speicherkosten Kosten für die primäre Kopie der Daten, für Replikations-PUT-Anforderungen und für den Speicherabruf an. Bei CRR wird auch für den regionenübergreifenden Datentransfer OUT von S3 zu jeder Zielregion gezahlt. Die Preise für Speicher- und PUT-Anfragen für die replizierte Kopie basieren auf den ausgewählten AWS-Zielregionen, während die Preise für Datenübertragungen zwischen den Regionen auf der AWS-Quellregion basieren. Wenn man S3 Replication Time Control nutzt, wird eine Datenübertragungsgebühr für die Replikationszeitsteuerung sowie Gebühren für S3-Replikationsmetriken erhoben, die zum selben Tarif abgerechnet werden wie angepasste Amazon-CloudWatch-Metriken. Die Kosten für die S3 Replication Time Control-Datenübertragung beträgt pro GB 0.015 USD. Unter [AWS Preise](#) können diese Informationen abgerufen werden.

Im Zusammenhang mit der Objektversionierung entstehen Kosten für die Beibehaltung älterer Versionen von Objekten, da zusätzlicher Speicherplatz benötigt wird. Es fallen keine direkten Kosten für das Tagging von benutzerdefinierten Metadaten an, die den Objekten zugeordnet sind. Es ist jedoch möglich, dass Kosten für das Abrufen von Tags über die S3-API (z. B. mit den ListObjects- oder GetObject-Operationen) anfallen, da dies als Datenabruf betrachtet wird und entsprechende Gebühren gemäß den AWS-Preisen für Datenzugriff erhoben werden.

Die genauen Preise und Kostendetails für S3 können sich im Laufe der Zeit ändern. Es wird empfohlen, die aktuellsten Informationen auf der offiziellen AWS-Preisseite oder im AWS-Kostenrechner unter [AWS Calculator](#) zu überprüfen, um eine grobe Kosteneinschätzung zu erhalten.

GC Storage

GCS setzt Preise für die Komponenten Datenspeicher, Datenverarbeitung und Netzwerknutzung. Beim Datenspeicher ist, wie bei Amazon S3, die Menge der in Buckets gespeicherten Daten relevant. Preise für Speicher hängen von der Speicherklasse der Daten und dem Standort der Buckets ab. Bei der Verarbeitung werden Gebühren für die von Cloud Storage durchgeführten Verarbeitung, einschließlich Vorgangsgebühren, anwendbarer Abrufgebühren und Replikation zwischen Regionen erhoben. Bei der Netzwerknutzung werden Gebühren für die Menge der aus den Buckets gelesenen oder zwischen diesen verschobenen Daten erhoben. GC Storage bietet vier Speicherklassen an, von denen drei untersucht werden. Die Archive Speicherklasse wird dabei nicht berücksichtigt, daDie Standard, Nearline und Coldline. Diese drei Speicherklassen haben unterschiedliche Leistungseigenschaften und Kosten.

Die nachfolgende Tabelle zeigt den Unterschied der Speicherklassengebühren von GC Storage und dient als Vergleich zu Amazon S3:

	Standard	Nearline	Coldline
Speicher/GB im Monat	0.021 EUR	0.012 EUR	0.0054 EUR
Vorgänge Klasse A pro 1000 Vorgänge	0.0047 EUR	0.0093 EUR	0.0093 EUR
Vorgänge Klasse B pro 1000 Vorgänge	0.00037 EUR	0.00093 EUR	0.0047 EUR
Datenabrufe pro GB	–	0.0093 EUR	0.019 EUR
Ausgehender Traffic von GC ins Internet monatlich	0.11 EUR pro 0 bis 1TB		

Tabelle 2.2.4: Vergleich der Kosten von Google Cloud Storage Speicherklassen

Die Kosten der Speicherung von GC unterscheiden sich von AWS um 3. Hier gibt es kaum Unterschied zwischen der Standard beider Provider und die Nearline mit dem Standard-IA. Jedoch ist die One Zone-IA mit 0.010 Euro um 46% teurer als die Coldline von GC. Für die Klasse A Vorgänge verlangt GC Gebühren in Höhe von 0.0047 Euro für Standard und 0.0093 Euro für die Nearline und Coldline. Letztere zwei Klassen haben die gleichen Kosten wie die Standard-, und One Zone-IA. Die GC Standard Klasse ist um 6% billiger als die S3 Standard. Für die Klasse B fallen Gebühren in Höhe von 0.00037 Euro für die Standard Klasse, 0.00093 Euro für die Nearline und 0.0047 Euro für Coldline. Auch hier gibt es zwischen Standard GC und S3 Preisunterschiede von 7.5% und zwischen Coldline und One Zone-IA von 80.43%. Es fallen extra Datenabrufgebühren für die Nearline und Coldline pro GB an. Hier sind die Gebühren um bis zu 95% höher als bei S3. Zuletzt werden für ausgehende Anfragen von GC ins Internet 0.11 Euro pro 0 bis 1TB Speicher erhoben, das 23.63% teurer als AWS ist.

Ähnlich wie bei Amazon S3 sind die Speicherkosten der Nearline und Coldline geringer als in der Standard Speicherklasse. Dafür werden Gebühren für die Datenabrufe bei Nearline und Coldline erhoben. Die verschiedenen Speicherklassen sind für unterschiedliche Anwendungsfälle ähnlich wie bei Amazon S3 konzipiert.

Die Standard Storage-Klasse beider Provider bietet hohe Performance, niedrige Latenzzeiten und hohe Verfügbarkeit. Sie eignet sich für häufig abgerufene Daten, auf die schnell zugegriffen werden müssen und geringe Latenzen aufweisen. Beispiele dafür sind aktive Anwendungen und Datenbanken.

Die Nearline Storage-Klasse ist für seltener abgerufene Daten konzipiert, auf die jedoch mit niedriger Latenzzeit zugegriffen werden müssen. Sie bietet niedrigere Speicherkosten als die Standard Storage, jedoch mit einer etwas längeren Zugriffszeit. Sie eignet sich für Backup-Daten, Archivierung, lange Speicherung und bietet ähnliche Funktionen wie die Standard-IA von S3 .

Die letzte Speicherklasse Coldline Storage ist für Daten ausgelegt, auf die selten zugegriffen wird und bei denen eine längere Zugriffszeit akzeptabel ist. Sie bietet die niedrigsten Speicherkosten und eignet sich für langfristige Archivierung, Compliance-Daten und Backup-Daten.

Zusätzlich werden für Replikation von Daten Gebühren erhoben, die nicht in der Tabelle aufgelistet sind. Auf Wunsch können Nutzer in GC Storage Daten innerhalb einer Region, in Dual-Regionen oder Multiregionen replizieren. Zusätzlich zu den Daten, die in den hochgeladenen Objekten enthalten sind, werden benutzerdefinierte Metadaten auf die monatliche Speichernutzung angerechnet. Für die benutzerdefinierten Metadaten `NAME:VALUE` erfasst GC Storage beispielsweise jedes Zeichen in `NAME` und `VALUE` als Byte, das mit dem Objekt gespeichert wird.

Beim vorzeitigen Löschen eines Objekts aus den Speicherklassen Coldline und Nearline werden Gebühren erhoben, da eine Mindestspeicherdauer angesetzt wird. Das vorzeitige Löschen beim Nearline beträgt pro GB pro Tag ca. 0.00043 USD und beim Coldline 0.0002 USD. Auch für Tags fallen Gebühren pro Monat von 0.005 USD an, welche auf Buckets angewendet werden.

Auch bei GC fallen Kosten für die Objektversionierung an. Die Kosten setzen sich aus zwei Hauptkomponenten zusammen: Speicher und Anfragen. Jede Version eines Objekts belegt Speicherplatz im Bucket. Die Kosten basieren auf der Größe der Objekte und der Anzahl der gespeicherten Versionen. Das Hochladen, Herunterladen oder Löschen von Objektversionen führt zu Anfragen an den Storage-Dienst. Für diese Anfragen können Gebühren anfallen, die sich nach der Anzahl der Anfragen richten. Es ist wichtig zu beachten, dass die Kosten für die Objektversionierung zusätzlich zu den regulären Kosten für die Speicherung und den Datenverkehr in GC Storage anfallen. Daher sollten die potenziellen Kosten der Objektversionierung in den Kalkulation einbezogen werden.

2.2.1.4 Performance

Amazon S3

Amazon S3 bietet Funktionen und Dienste, welche Performance und Skalierbarkeit der Datenzugriffe verbessern. In der offiziellen Dokumentation [S3: Performance Guidelines for Amazon S3](#), [15] werden Best Practices Guidelines empfohlen, welche die Leistung erhöhen können. Es wird empfohlen HTTP Analyse Tools zu verwenden, um die Leistung von DNS lookup times, Latenzen und die Datentransfer-Geschwindigkeiten zu messen.

Eine andere Methode, welche die Leistung erhöhen kann, ist die horizontale Skalierung von Connections. Da Amazon S3 als ein sehr großes verteiltes System gilt, können Requests über getrennte Verbindungen verteilt werden, um die Bandbreite zu maximieren. „Amazon S3 doesn’t have any limits for the number of connections made to your bucket.“, [performance-guide](#) [ebd.](#)

Außerdem verspricht Amazon S3, dass Requests beim wiederholten Mal schneller sind, da sie einen anderen Pfad als beim ersten Request nehmen. „[...] if the first request is slow, a retried request is likely to take a different path and quickly succeed.“, [performance-guide](#) [ebd.](#)

Weitere Funktionen, die zur Leistungserhöhung beitragen, sind S3 Transfer Acceleration, S3 Select und die S3 Cross-Replication. Die S3 Transfer Acceleration ermöglicht schnelle, einfache und sichere Übertragungen von Dateien über große geografische Distanzen hinweg zwischen dem Client und S3 Buckets. Die Daten werden über eine optimierte Route an Amazon S3 weitergeleitet. Diese Funktion ist für Daten in Größe von Gigabytes zu Terabytes geeignet, die regelmäßig verschickt werden müssen. Um die Dauer der Anfragen zu messen, bietet Amazon S3 das S3 Transfer Acceleration Speed Comparison Tool an, um beschleunigte und nicht-beschleunigte Uploads zu messen. Unter [S3 Accelerate Speedtest](#) kann der Vergleich zwischen aktivierter und deaktivierter Transfer Acceleration beobachtet werden.

S3 Select ermöglicht das effiziente Abrufen von spezifischen Daten aus Objekten in Amazon S3. Anstatt ein gesamtes Objekt herunterladen zu müssen, können mit S3 Select nur die benötigten Daten abgefragt werden. Dies reduziert den Datenverkehr und beschleunigt den Abrufvorgang erheblich, insbesondere bei großen Daten.

Die im Abschnitt erwähnten CRR und SRR Techniken können ebenfalls für eine höhere Performanz beitragen, indem Daten in andere Regionen repliziert werden und für Nutzer näher erreichbar sind.

Das AWS SDK stellt eine einfache API und wird regelmäßig gewartet, um die neuesten Technologien anzubieten. Das SDK beinhaltet die automatische Retry Request bei HTTP 503 Fehlern. Es beinhaltet auch den Transfer Manager, der dafür sorgt Connections automatisch horizontal zu skalieren. Damit können tausende von Requests pro Sekunde verschickt werden.

GC Storage

Auch GC Storage ermöglicht analog zu CRR und SRR von AWS die Auswahl des geeigneten Speicherorts für Daten, um die Latenzzeiten zu minimieren. Es kann zwischen multi-regionalen Speicherstandorten oder regionalen Speicherstandorten gewählt werden, um Daten näher an den Benutzer zu bringen oder Anwendungen zu speichern, um den Zugriff zu beschleunigen.

Durch die Integration mit Content Delivery Networks (CDNs) kann die globale Verteilung von Daten optimiert und die Bereitstellung beschleunigt werden. Die CDN stellt eine Zwischenspeicherung von Inhalten in Edge-Servern weltweit bereit, um den Zugriff auf Daten schneller zu gestalten.

Bei der Performance hat die Request Rate eine relevante Rolle. Das bietet das Auto-Scaling von GCP an. Cloud Storage ist ein multi-tenant Service, was bedeutet, dass Benutzer die zugrunde liegenden Ressourcen gemeinsam nutzen. Um gemeinsame Ressourcen optimal zu nutzen, haben Buckets eine anfängliche I/O Kapazität.

„Cloud Storage is a multi-tenant service, meaning that users share the same set of underlying resources[...]”, ^{[gcp-autoscale](#)} Cloud: Request rate and access distribution guidelines: Auto Scaling, [5] (Übersetzung aus Google Cloud)

Diese I/O Kapazitäten betragen etwa 1000 Schreibzugriffsanfragen pro Sekunde für Objekte, einschließlich Hochladen, Aktualisieren und Löschen von Objekten. Es ist zu beachten, dass Cloud Storage auch eine kleinere Begrenzung für wiederholte Schreibvorgänge mit demselben Objektnamen hat. Auf Lesezugriffe betragen die Kapazitäten etwa 5000 Anfragen pro Sekunde, einschließlich Auflisten von Objekten, Lesen von Objektdaten und Lesen von Objektmetadaten, vgl. ^{[gcp-autoscale](#)} [ebd.](#)

Wenn die Anfragehäufigkeit für ein bestimmtes Bucket steigt, skaliert Cloud Storage automatisch und erhöht die I/O Kapazität für diesen Bucket, indem die Anfragelast auf mehrere Server verteilt wird.

Cloud Storage ermöglicht den parallelen Upload und Download von Daten, um die Übertragungsgeschwindigkeit zu maximieren. Es können mehrere Threads oder Prozesse verwendet werden, um Daten gleichzeitig hochzuladen oder herunterzuladen und so die Leistung zu verbessern. Dies ähnelt dem horizontalen Skalieren von AWS, bei dem mehrere Verbindungen auf Buckets hergestellt werden können.

Der GC Storage Transfer Service ermöglicht den schnellen und effizienten Transfer von großen Datenmengen. Daten können aus anderen Cloud-Speicherlösungen, On-Premise-Speichern oder öffentlichen Datensätzen in GC Storage übertragen werden, um Zeit und Bandbreite zu sparen. Diese Vorgehensweise entspricht auch dem Transfer Acceleration von AWS, bei denen große Datenmengen schneller an andere Ziele übertragen werden.

GC empfiehlt Einstellungen, um die Performance zu optimieren. Um die Leistung messen zu können, bietet GC das **perfdiag** Tool an. Der Autor McAnlis empfiehlt in seinem Block ^{[gcp-blog](#)} [Optimizing your Cloud Storage performance: Google Cloud Performance Atlas](#) dieses Tool zu verwenden, dass eine Reihe von Tests durchläuft, die die aktuelle Performance von einem Cloud Bucket proto-

kolliert. Des Weiteren empfiehlt er die Nutzung des `gsutil` Tools von GC, um kleinere Dateien schneller hochzuladen. Wenn 20 000 Dateien, die jeweils 1kb groß sind hochgeladen werden, dauert der Overhead bei jedem individuellen Upload länger als die gesamte Uploadzeit. Deshalb sollte man Batch Operationen verwenden, da diese den Overhead reduzieren und die Leistung verbessern. Das `gsutil` Tool bietet die Option an, Batch Operationen durchzuführen.

Auf dem folgenden Diagramm wird ein Test mit hundert mal 200 000 Dateien mit individuellem Upload und Batch Upload angezeigt, das mit `gsutil -m cp` in ein Storage Bucket hochgeladen wird:



Abbildung 2.2.1: GCS Dauer des Uploads, [gcp-blog
https://cloud.google.com/blog/products/gcp/optimizing-your-cloud-storage-performance-google-cloud-performance-atlas/](https://cloud.google.com/blog/products/gcp/optimizing-your-cloud-storage-performance-google-cloud-performance-atlas/)

Hier sieht man, wie die Leistung sich dabei um das fünffache im Gegensatz zu den individuellen Uploads erhöht. Das Auto-balancing von GC sorgt für die Verteilung der Upload-Connections auf "Backend Shards". Das funktioniert durch die Name/Pfad der Datei und kann die Dauer des Uploads erhöhen, wenn sich die Dateien in unterschiedlichen Ordnern befinden oder auch verschiedene Namensgebungen haben. Falls sich die Dateien zu sehr ähneln, kann dies die Dauer des Uploads reduzieren, da die Connections in den gleichen Shard übergehen.

Eine weitere Methode zur Performancesteigerung, sind Requests in Größen ab 1MB. Bei kleineren Requests sollten die Requests parallelisiert werden, damit die fixen Latenzkosten überlappt werden.

Es ist zu beachten, dass die Performance auch von anderen Faktoren abhängt, wie der Anwendungsarchitektur und der Netzwerkverbindung. Es können spezifische Konfigurationsoptionen genutzt werden, um die Leistung weiter zu optimieren, wie Caching, asynchrone Operationen oder die Nutzung von optimierten Bibliotheken oder Frameworks.

2.2.1.5 API Anbindung

Amazon S3

Die API-Anbindung von Amazon S3 ist umfangreich und bietet Entwicklern eine Vielzahl von Möglichkeiten zur Interaktion mit dem Speicherdienst. Amazon S3 bietet eine RESTful API (Application Programming Interface) sowie verschiedene SDKs (Software Development Kits) und Tools, welche die Integration und Nutzung erleichtern.

Amazon S3 bietet eine RESTful API, die auf dem HTTP-Protokoll basiert. Mit dieser API können Entwickler HTTP-Anfragen wie GET, PUT, POST und DELETE verschicken, um auf Buckets und Objekte zuzugreifen, zu erstellen, zu lesen, zu aktualisieren und zu löschen. Amazon empfiehlt die Verwendung des AWS SDK, da bei Verwendung der REST API zusätzlicher Code zur Berechnung der gültigen Signatur für die Authentifizierung geschrieben werden muss. „It requires you to write the necessary code to calculate a valid signature to authenticate your requests.“, ^{aws-api} S3: Amazon S3 REST API Introduction, [13].

Die Authentifizierung von Requests im AWS SDK erfolgt durch die Bereitstellung von Access Keys, wodurch das Schreiben von Code dafür entfällt. Das SDK ist in verschiedenen Programmiersprachen verfügbar, darunter Java, JavaScript, Python, .NET, Ruby, PHP, iOS und Android. Die folgende Tabelle enthält eine Auflistung aller unterstützten Programmiersprachen:

SDK documentation	Code examples
AWS SDK for C++	AWS SDK for C++ code examples
AWS SDK for Go	AWS SDK for Go code examples
AWS SDK for Java	AWS SDK for Java code examples
AWS SDK for Javascript	AWS SDK for Javascript code examples
AWS SDK for Kotlin	AWS SDK for Kotlin code examples
AWS SDK for .NET	AWS SDK for .NET code examples
AWS SDK for PHP	AWS SDK for PHP code examples
AWS SDK for Python(Boto3)	AWS SDK for Python(Boto3) code examples
AWS SDK for Ruby	AWS SDK for Ruby code examples
AWS SDK for Rust	AWS SDK for Rust code examples
AWS SDK for Swift	AWS SDK for Swift code examples

Tabelle 2.2.5: Unterstützte Programmiersprachen von AWS SDK, ^{aws-sdk} <https://docs.aws.amazon.com/AmazonS3/latest/userguide/UsingAWSSDK.html>

Das SDK bietet eine Schnittstelle, um die Entwicklung von Anwendungen zu erleichtern und die Interaktion mit Amazon S3 zu vereinfachen. Darüber hinaus gibt es auch Drittanbieter-Tools und Open-Source Bibliotheken, die die Integration mit Amazon S3 unterstützen. Spring Boot stellt eine Bibliothek für die alte und neue Version von AWS SDK zur Verfügung. IntelliJ Idea bietet den Plugin AWS Toolkit an, mit dem Amazon Credentials zur Verfügung gestellt werden können.

Dieses Plugin gibt es auch für Eclipse und Visual Studio Code.

Außerhalb der AWS SDK stellt Amazon S3 auch das AWS CLI (Command Line Interface) bereit, um API Aufrufe durchzuführen. Amazon S3 ermöglicht die Durchführung von Batch-Operationen, um mehrere Objekte in einem einzigen API-Aufruf zu verarbeiten. Dies erleichtert die effiziente Verarbeitung großer Datenmengen und reduziert die Anzahl der API-Anfragen.

Die API-Anbindung von Amazon S3 erfordert eine geeignete Authentifizierung und Autorisierung. Dies erfolgt in der Regel mithilfe von Zugriffsschlüsseln, die über AWS Identity and Access Management (IAM) verwaltet werden.

Google Cloud Storage

Auch GC Storage bietet umfangreiche API-Integrationen, um die Einbindung in eigene Anwendungen zu ermöglichen. Eine davon sind die Client Libraries für verschiedene Programmiersprachen wie Java, Python, Node.js, Go, Ruby und .NET. Diese Bibliotheken erleichtern die Integration von GC Storage in Anwendungen und bieten eine benutzerfreundliche Schnittstelle für die Interaktion mit den Speicherressourcen. Auch in Cloud Storage wird eine RESTful API ähnlich wie in Amazon S3 angeboten. Diese ermöglicht es Entwicklern über HTTP-Anfragen auf die Speicherressourcen zuzugreifen. Sie unterstützt CRUD Operationen für Buckets und Objekte sowie erweiterte Funktionen wie das Setzen von Metadaten, das Verwalten von Zugriffssteuerungen und das Durchführen von Batch-Anfragen.

Google Cloud Storage bietet sowohl JSON- als auch XML-APIs für die Interaktion mit dem Speicherdienst. Die JSON-API ist die bevorzugte Option und bietet eine moderne, leichtgewichtige Syntax für die Kommunikation mit dem Dienst anstelle der RESTful API. Neben der direkten API-Anbindung stellt Google auch das GC SDK zur Verfügung, das verschiedene Befehlszeilen-tools enthält, mit denen auf Speicherressourcen zugegriffen und verwaltet werden kann. Neben den Client-Bibliotheken werden auch Tools wie `gsutil` (ein Befehlszeilen-Dienstprogramm) bereitgestellt. Dies ermöglicht, Cloud Storage von der Befehlszeile aus zu verwalten. Cloud Storage FUSE ermöglicht, Cloud Storage als Dateisystem zu mounten und direkt darauf zuzugreifen.

Die API-Anbindung von GC Storage erfordert ebenfalls eine Authentifizierung und Autorisierung. Dies wird mithilfe von GC IAM (Identity and Access Management) verwaltet, das Zugriffsrichtlinien und Rollenverwaltung bietet, ähnlich wie bei AWS.

Mit Terraform können Konfigurationen von GC Storage Buckets und Amazon S3-Buckets und die dazugehörigen Einstellungen in einer Terraform-Konfigurationsdatei spezifiziert werden. Diese Konfigurationsdatei enthält Informationen wie den Bucket-Namen, Zugriffsrechte, Verschlüsselungsoptionen und andere relevante Parameter. Terraform ist ein sogenanntes Infrastructure-as-Code-Tool, mit dem Infrastrukturressourcen in verschiedenen Cloud-Umgebungen, einschließlich GC und AWS, automatisiert erstellt und verwaltet werden können. Terraform sendet erforderliche API-Anfragen an GC oder AWS um den Bucket entsprechend der Konfiguration zu erstellen oder zu aktualisieren. Durch die Verwendung von Terraform für beide Cloud Provider kann die Infrastruktur als Code behandelt werden, wodurch die Konfiguration wiederholbar, versionierbar und leicht reproduzierbar wird. Auch können die Vorteile der Funktionen von Terraform genutzt werden, wie z.B. die Verwaltung von Abhängigkeiten zwischen Ressourcen, die Verwendung von Variablen und Modulen sowie die Integration in CI/CD-Pipelines.

2.2.2 Bereitstellung der Dateien

In diesem Abschnitt werden Methoden für die Bereitstellung der Dateien durch signierte URL's von Amazon S3 und Cloud Storage präsentiert. Unternehmen und Organisationen stehen vor der Herausforderung, Dateien sicher und effizient für ihre Benutzer bereitzustellen. Eine häufig dafür verwendete Methode, ist die Verwendung signierter URL's. Diese ermöglichen es, auf einfache Weise temporäre Zugriffsrechte für Dateien zu gewähren, ohne komplexe Zugriffskontrollmechanismen implementieren zu müssen. Sowohl AWS S3 als auch GC Storage bieten die Möglichkeit, signierte URLs für die Dateibereitstellung zu generieren. Beide bieten ähnliche Funktionen an, signierte URLs durch die SDKs zu generieren.

Amazon S3

In Amazon S3 sind alle Objekte und Buckets standardmäßig privat. Durch die Verwendung von presigned URLs können Objekte bereitgestellt werden, ohne die Voraussetzung, ein AWS Konto zu besitzen. „All objects and buckets are private by default. However, you can use a presigned URL to share objects with others.“, [aws-signed-urls](#) S3: Using presigned URLs, [16].

Presigned URLs werden für die Generierung von Links verwendet, um auf S3 Buckets und Objekte zugreifen zu können. Bei der Erstellung eines solchen URLs können andere Nutzer von außerhalb AWS ohne Credentials auf die gewünschten Daten zugreifen. Jeder, der diesen Link hat, kann darauf zugreifen und Aktionen ausführen. Der Link verliert ab Konfiguration nach einer bestimmten Zeit die Gültigkeit. Amazon S3 überprüft das Verfallsdatum des Links während des HTTP Requests, vgl. [aws-signed-urls](#) [ebd.](#)

Durch die Nutzung einer URL können Nutzer Objekte lesen oder hochladen. In Fall von leoticket liegt das Lesen des Objekts im Fokus. Die URL beinhaltet spezielle Parameter, welche von einer Anwendung gesetzt werden. Es gibt drei Parameter, um den Zugriff für den Nutzer einzuschränken. Diese sind einmal Einschränkung des Buckets. Das bedeutet, dass ein Nutzer nicht auf jeden Bucket zugreifen kann, sondern nur auf den Bucket, indem sich das Objekt befindet. Der zweite Parameter ist der Name des Objekts und zuletzt die Zeitspanne in der die URL gültig ist. Sobald die Zeit abgelaufen ist, kann der Nutzer nicht mehr auf den Link zugreifen.

Durch die Methode der presigned URLs können diese Links über die Email an die Clients versendet werden. Somit kann die Bereitstellung der erfassten Daten des Produkts leoticket über die presigned URLs stattfinden und Email-Anhänge vermieden werden.

Google Cloud Storage

In GC Storage funktioniert die signed URL gemäß einem ähnlichen Prinzip wie in Amazon S3. Durch zeiteingeschränkte Links können Nutzer, welche den Link besitzen, ohne GC Credentials auf Objekte und Buckets zugreifen. Dabei bietet Cloud Storage mehrere Methoden zur Generierung einer Signed URL an. Die V4 signing with service account authentication, Signing with HMAC authentication und die V2 signing with service account authentication. Letztere Methode wird ausgeschlossen, da sie von GC selbst nicht empfohlen wird. Ein Beispiel, wie eine signierte URL aussehen kann:

```
1 https://storage.googleapis.com/[BUCKET_NAME]/[OBJECT_NAME]?GoogleAccessId=[  
SERVICE_ACCOUNT_EMAIL]&Expires=[EXPIRATION_TIMESTAMP]&Signature=[URL_SIGNATURE]
```

Hierbei sind die Platzhalter wie folgt zu ersetzen:

- BUCKET_NAME - Der Name des GCS-Buckets, in dem sich das Objekt befindet.
- OBJECT_NAME - Der Name des Objekts, für das die signierte URL generiert werden soll.
- SERVICE_ACCOUNT_EMAIL - Die E-Mail-Adresse des Service Accounts, der die Zugriffsberechtigung hat.
- EXPIRATION_TIMESTAMP - Das Ablaufdatum der signierten URL in Form eines Unix-Timestamps.
- URL_SIGNATURE - Die Signatur der URL, die den Zugriff autorisiert.

Im Vergleich zu AWS unterscheiden sich die Parameter bei der Zugriffsberechtigung. In AWS wird der ACCESS_KEY statt die Service Account Email verwendet. Der Access Key ist dabei der Zugriffsschlüssel des AWS-Kontos, das die Zugriffsberechtigung hat.

2.3 Auswahl des Speichersystems

In diesem Kapitel werden anhand der Anforderungen an leoticket die Kostenanalyse durchgeführt und Konfigurationseinstellungen empfohlen.

2.3.1 Kostenanalyse

Bei der Kostenanalyse werden die Gebühren aus dem Kosten Abschnitt übernommen und eine Kostenabschätzung für Amazon S3 und Cloud Storage durchgeführt. Es werden die Kosten für die Speicherung, Abrufen und Datenübertragung verglichen und dargestellt. Die Berechnungsdaten sind zufällig und realitätsnah ausgewählt und dienen der groben Kosteneinschätzung. Dabei wurden die aktuellsten Gebühren aus der offiziellen Dokumentation von AWS und GC übernommen.

Für eine grobe Kosteneinschätzung wird von durchschnittlich 800 000 Bestellungen pro Jahr ausgegangen. Dies entspricht etwa 67.000 Bestellungen pro Monat , wobei jede Bestellung 4 Objekte enthält. Die durchschnittliche Größe eines Objektes beträgt dabei 100KB. Für jede Bestellung wird von durchschnittlich drei Ticketkäufen ausgegangen, bei denen eine zusätzliche Rechnung hinzugefügt wird. Dadurch werden monatlich etwa 268.000 POST-Anfragen an Buckets verschickt. Außerdem wird erwartet, dass Objekte zweimal im Monat abgerufen werden, einmal von Leomedia und einmal von Kunden. Insgesamt wird es 536.000 GET-Anfragen geben. Es ist zu beachten, dass jedes Objekt einzeln hochgeladen wird.

Die Speichergröße wird durch die Multiplikation der Anzahl von 67.000 Bestellungen pro Monat mit der Größe von 400 KB pro Bestellung ermittelt. Dieses Ergebnis wird durch 1024 geteilt und das resultierende Ergebnis erneut durch 1024 geteilt, um die Größe in GB zu erhalten. Dies ergibt eine monatliche Speichergröße von 25 GB. Unter Berücksichtigung einer Aufbewahrungsdauer von 10 Jahren ergibt sich eine geschätzte Datenmenge von etwa 3 TB, wenn die Daten nach 10 Jahren gelöscht werden. Für die Preisberechnung werden diese Daten in die [AWS Preisrechner](#) und [GC Preisrechner](#) eingesetzt.

Amazon S3

Im Folgenden stellt die Tabelle die monatlichen Kosten der verschiedenen Speicherklassen dar. Die Vorabkosten, die unten berechnet werden, müssen an AWS gezahlt werden:

	Standard	Intelligent Tiering	Standard-IA	One Zone-IA
Speicherkosten	70.27 EUR	70.27 EUR	38.72 EUR	30.98 EUR
Vorabzahlung	162.42 EUR	162.42 EUR	300.76 EUR	300.76 EUR
PUT Requests	1.35	1.35 EUR	2.50 EUR	2.50 EUR
GET Requests	0.22 EUR	0.22 EUR	0.50 EUR	0.50 EUR
Datenabrufe	–	–	0.47 EUR	0.47 EUR
Data Transfer	4.20 EUR			
Monitoring und Automation objects	–	75.19 EUR	–	–

Tabelle 2.3.1: Übersicht der einzelnen Kosten der Datenspeicherung in Amazon S3

Zunächst werden die Einheitsumwandlungen durchgeführt. Hierbei wird die angegebene Datenmenge von 3 TB pro Monat mit 1024 GB multipliziert, um die genaue Menge in GB zu berechnen. Das ergibt einen Wert von 3072 GB. Daraufhin wird die Objektgröße von 100 KB in GB umgerechnet, was einem Wert von 0,000095367432 GB entspricht. Anschließend werden die Preise anhand dieser berechneten Werte ermittelt:

$$\frac{3072 \text{ GB per Month}}{0.000095367432 \text{ GB average item size}} = 32.212.255 \text{ number of objects} \quad (3.1)$$

$$3072 \text{ GB} \times 0.013 \text{ EUR} = 38.72 \text{ EUR Standard-IA costs} \quad (3.2)$$

$$268.000 \text{ PUT requests} \times 0.0093 \text{ EUR per request} = 2.50 \text{ EUR (PUT requests cost)} \quad (3.3)$$

$$536.000 \text{ GET requests} \times 0.00093 \text{ EUR per request} = 0.50 \text{ EUR (GET requests cost)} \quad (3.4)$$

$$50 \text{ GB} \times 0.00093 \text{ EUR} = 0.47 \text{ EUR (data retrievals cost)} \quad (3.5)$$

$$38.72 \text{ EUR} + 2.50 \text{ EUR} + 0.50 \text{ EUR} + 0.47 \text{ EUR} = \underline{\underline{42.19 \text{ EUR (Total Standard-IA)}}} \quad (3.6)$$

$$32.212.255 \text{ number of objects} \times 0.0000093 \text{ EUR} \quad (3.7)$$

$$= 300.76 \text{ EUR (Cost for PUT, COPY, POST requests for initial data)} \quad (3.8)$$

Die oben genannten Formeln ähneln denen für die Speicherklassen Standard und One Zone-IA, wobei die entsprechenden Gebühren aus dem Kostenabschnitt übernommen wurden. Bei der Intelligent Tiering gibt es jedoch einen Unterschied: Es fallen zusätzliche Kosten für Überwachung und Automatisierung an, und der Speicher wird in drei Klassen prozentual aufgeteilt. In der letzten Zeile der Tabelle werden die Gesamtkosten zusammen mit den Kosten für den Datentransfer, eventuelle Vorauszahlungen (zusätzlich in 3.8) und die reinen monatlichen Speicherkosten für die jeweiligen Speicherklassen addiert.

GC Storage

Die nachstehende Tabelle stellt eine Zusammenfassung der monatlichen Kosten für drei Speicherklassen von GC Storage dar:

	Standard	Nearline	Coldline
Speicherkosten	63.75 EUR	36.03 EUR	16.63 EUR
Datenabrufe	–	0.45 EUR	0.90 EUR
Klasse A Operationen	1.21 EUR	2.42 EUR	4.84 EUR
Klasse B Operationen	0.19 EUR	0.48 EUR	4.84 EUR
Internet Egress	3.83 EUR pro 0 bis 1TB		

Tabelle 2.3.2: Übersicht der einzelnen Kosten der Datenspeicherung in GC Storage

Die Speicherkategorie mit den höchsten Kosten von 63,75 Euro ist die Standardklasse. Die Coldline-Kategorie ist die kostengünstigste Option mit Kosten von 16,63 Euro. Die Nearline-Kategorie ist teurer als die Coldline-Kategorie und kostet 36,03 Euro. In der Standardklasse fallen keine Gebühren für den Datenabruf an, während für Nearline 0,45 Euro und für Coldline 0,90 Euro berechnet werden. In Klasse A ist die Nearline-Kategorie mit 2,42 Euro doppelt so teuer wie die Standardklasse, während die Coldline-Kategorie mit 4,84 Euro doppelt so teuer wie die Nearline-Kategorie ist. In Klasse B ist die Standardklasse mit 0,19 Euro am günstigsten, während die Nearline-Kategorie etwa doppelt so teuer ist. Die Coldline-Kategorie ist hier etwa zehnmal teurer als die Nearline-Kategorie. Für den Internet-Ausgangsverkehr fallen Gebühren von 3,83 Euro pro 0 bis 1 TB monatlich an. Die Tabelle zeigt, dass die Standardklasse doppelt so teuer ist wie die Nearline-Kategorie und etwa dreimal so teuer wie die Coldline-Kategorie. Die Preise ergeben sich durch die unterschiedlichen Anwendungsfälle der Speicherkategorien, die in der Entscheidungsfindung genauer erklärt werden.

2.3.2 Entscheidungsfindung

Um der Anforderung der sicheren Speicherung des Produkts leoticket zu entsprechen, bieten beide Cloud Provider Funktionen an, die im vorherigen Kapitel unter Eigenschaften untersucht worden sind. Beide Cloud Provider bieten ähnliche Funktionen für die Erstellung von Benutzern, Gruppen und Rollen, um den Zugriff auf die Dienste einzuschränken. Die IAM Funktion beider Cloud Provider ermöglichen die Beschränkung des Zugriffs auf S3 und Cloud Storage. Bei der IAM-Funktion in AWS S3 werden Vorgehensweisen empfohlen, um die Sicherheit und den Zugriff auf S3-Ressourcen zu verbessern. Zum einen das Prinzip des geringsten Privilegs. Benutzern und Anwendungen sollten nur die Berechtigungen, die sie zum Durchführen ihrer Aufgaben benötigen, gewährt werden. Überflüssige Berechtigungen sollten vermieden werden. Das beinhaltet beispielsweise Schreib- und Leseberechtigungen für Objekte. Es können auch andere Berechtigungen, wie das Hinzufügen von Richtlinien, vergeben werden. Diese Empfehlung gilt auch für die IAM-Funktion in GC. Für die Authentifizierung von Anwendungen stehen Service Accounts zur Verfügung, die spezifische Berechtigungen haben, welche für die Anwendung relevant sind. Für jeden Dienst oder jede Anwendung kann ein eigener Service Account erstellt werden.

Auch bei der Datenverschlüsselung bieten beide Cloud Provider ähnlichen Möglichkeiten, mit Encryption Keys umzugehen. Da leoticket eine sichere Speicherung anfordert, kommt die SSE-KMS customer-managed Variante in Frage. Durch die selbstständige Generierung des Schlüssels und Verwaltung hat der Nutzer im Gegensatz zu S3-managed oder Google-managed Keys mehr Kontrolle. Die generierten Schlüssel werden jedoch vom Cloud-Anbieter im KMS gespeichert. Wenn die Option SSE-KMS gewählt wird, kann die Funktion Bucket Keys in S3 aktiviert werden. Dadurch wird ein Master Key verwendet, der die Schlüssel der einzelnen Objekte verschlüsselt. Dies führt zu einer Reduzierung der Request-Kosten um bis zu 99 Prozent, da der Request-Verkehr von S3 zu AWS KMS verringert wird.

Um eine größere Unabhängigkeit vom Cloud-Anbieter zu gewährleisten, kann die Option customer-supplied in GC oder die Option customer-managed in S3 in Betracht gezogen werden. In diesem Fall trägt der Nutzer die volle Verantwortung für die Schlüssel. Das bedeutet, dass die Schlüssel extern vom Nutzer generiert, verwaltet und gespeichert werden. Es besteht jedoch das Risiko, dass der Schlüssel verloren geht und der Zugriff auf die Objekte in S3 oder Cloud Storage nicht mehr möglich ist. Darüber hinaus erfordert die eigenständige Verwaltung des Schlüssels einen höheren Aufwand im Vergleich zur Verwendung des KMS.

Beide Cloud-Anbieter bieten die Möglichkeit, ACLs auf Objekte und Buckets anzuwenden. Es wird jedoch empfohlen, ACLs auf Objektebene standardmäßig deaktiviert zu lassen und nur in Fällen zu verwenden, in denen der Uploader eines Objekts die vollständige Kontrolle über diese und auf andere Objekte eingeschränkten Zugriff in einem Bucket hat.

Um die Sicherheit und Verfügbarkeit von Daten zu gewährleisten, wird empfohlen, die Objektversionierung zu aktivieren, um mehrere Versionen von Objekten zur Verfügung zu stellen. Dadurch können Objekte bei versehentlichem Löschen oder Überschreiben wiederhergestellt werden. Diese Funktion wird von beiden Cloud-Providern angeboten und kann beim Erstellen eines Buckets aktiviert werden.

AWS und GC stellen eine Auswahl verschiedener Speicherklassen zur Verfügung. Beide Anbieter garantieren eine Verfügbarkeit von mindestens 99,9 Prozent. Die Speicherklassen Standard-IA und One Zone-IA bieten kostengünstigere Optionen für die Datenspeicherung. Die Standard-IA eignet sich für Daten, auf die seltener zugegriffen wird, die aber bei Bedarf schnell verfügbar sein müssen. Im Vergleich zur Standardklasse sind die Speicherkosten niedriger, jedoch fallen zusätzliche Gebühren für den Datenabruf an. Wenn Daten zwischen zwei Speicherklassen verschoben werden, entstehen Kosten für den Wechsel der Speicherklassen, die von der verschobenen Datenmenge abhängen.

Die Speicherklasse One Zone-IA eignet sich für Daten, auf die selten zugegriffen wird, weist jedoch eine Einschränkung auf. Im Gegensatz zu den anderen Speicherklassen wird One Zone-IA nur in einer einzigen Verfügbarkeitszone (AZ) in einer bestimmten Region gespeichert. Das bedeutet, dass die Daten nur in dieser einen AZ verfügbar sind und das Risiko besteht, dass die Daten nicht zugänglich sind, wenn diese spezifische AZ nicht verfügbar ist.

Für leoticket werden die Speicherklassen Standard-IA von S3 und Nearline von Cloud Storage empfohlen. Da in leoticket eine schnelle Dateiabfrage innerhalb von Millisekunden erforderlich ist, kommen die Speicherklassen S3 Glacier nicht in Betracht, da das Abrufen von Dateien in diesen Speicherklassen Tage oder Stunden dauern kann. Die Daten in leoticket müssen jederzeit abrufbereit sein, jedoch wird davon ausgegangen, dass Objekte im Durchschnitt nur zweimal abgerufen werden, einmal von der Anwendung selbst und einmal von den Kunden, die Tickets gekauft haben. Aufgrund der geringen Anzahl von Abrufen pro einzelnes Objekt und der erforderlichen Speicherung von Daten über einen Zeitraum von 10 Jahren sind die Speicherklassen Standard-IA und Nearline geeignete Optionen. Diese Speicherklassen sind für Daten ausgelegt, auf die seltener zugegriffen wird, aber bei Bedarf dennoch schnell verfügbar sein müssen. Sie bieten eine kostengünstigere Möglichkeit zur Speicherung der Daten, denn die Speicherung ist günstiger als bei den Standard Klassen. Die Speicherklasse One Zone-IA von S3, die die Daten nur in einer einzigen AZ speichert, wird aufgrund des Risikos einer eingeschränkten Verfügbarkeit bei Ausfall dieser spezifischen AZ nicht empfohlen. Dadurch kann sich die Zeit für den Abruf von Daten verlängern. Die Abrufkosten sind ebenfalls höher als bei anderen Speicherklassen, da diese Klasse nicht für Daten ausgelegt ist, auf die mindestens zweimal zugegriffen werden muss. Die Coldline-Speicherklasse von GC kann in Betracht gezogen werden, wenn Daten für eine längere Zeit nicht abgerufen wurden und auch in naher Zukunft nicht erwartet wird, dass sie wieder abgerufen werden. Die Coldline-Speicherklasse ist für Daten geeignet, auf die selten zugegriffen wird und bei denen eine längere Zugriffszeit akzeptabel ist. Sie eignen sich gut für die Archivierung von Daten. Hier könnte auf die Auto-Class Funktion von GC oder auf die Intelligent-Tiering von AWS zugegriffen werden, um Dateien automatisch in die passenden Speicherklassen zu verschieben. Jedoch fallen auch hier Gebühren bei der Nutzung dieser Funktionen an.

Im Hinblick auf die API-Integration gibt es einige Unterschiede zwischen den beiden Providern. Für leoticket ist es wichtig, dass die API nahtlos in die leoticket-Anwendung integriert werden kann, ohne großen Aufwand betreiben zu müssen. Beide Anbieter bieten geeignete SDKs, CLIs und REST APIs an, die problemlos in die eigene Anwendung eingebunden werden können. Es gibt auch Frameworks wie Spring Boot, die Bibliotheken für sowohl die AWS SDK-Version 1 und 2 als auch für GC bereitstellen. Ein Vorteil von AWS besteht darin, dass On-Premise-Anwendungen wie MinIO die AWS API verwenden und somit eine Kompatibilität mit S3 gewährleisten. Dies bedeutet, dass man bereits mit der API vertraut ist und Dateien über MinIO problemlos nach S3 hochladen und herunterladen kann. GC kann ebenfalls mit MinIO integriert werden. Dabei dient MinIO als Gateway. Nach den nötigen Konfigurationen kann auf GC Storage über den MinIO Server Endpoint zugegriffen werden. Dabei wird das Standard AWS S3 SDK für die Integration mit Cloud Storage verwendet. Jedoch erfordert es eine Einarbeitung in das AWS SDK als GC Storage Nutzer. Für die Authentifizierung mit der API wird empfohlen, bei Google Cloud die Verwendung von Service Accounts aus dem Google SDK zu nutzen. Es gibt jedoch auch andere Methoden zur Authentifizierung, und über das Application Default Credentials (ADC) in Google Cloud kann die bevorzugte Methode festgelegt werden. AWS bietet das **AWS Toolkit** zur Authentifizierung an, das von IntelliJ, Eclipse und anderen IDEs unterstützt wird. Die Verwendung des Toolkits wird zur Authentifizierung empfohlen. Insgesamt bieten sowohl AWS als auch Google Cloud gute Möglichkeiten zur API-Integration, wobei spezifische Faktoren wie Vorwissen, vorhandene Technologien und Anforderungen berücksichtigt werden sollten.

Um eine optimale Performance für leoticket zu gewährleisten, empfiehlt es sich, Performance-Analysen durchzuführen. Sowohl AWS als auch GC bieten Tools zur Unterstützung an. Bei GC kann die Performance-Diagnose mithilfe des `gsutil` CLI durchgeführt werden. Dies ist auch erforderlich, wenn der Support von GC kontaktiert wird, um bei der Fehlerbehebung zu helfen. AWS hingegen bietet im S3-Bucket Metriken an, die zur Performance-Analyse genutzt werden können. Es werden verschiedene Widgets für Request-Metriken bereitgestellt, die analysiert werden können, genauso wie GC. AWS hat jedoch keine speziellen Performance-Analyse Tools wie das `gsutil perfdiag` von GC. Im Kapitel „Prototypische Umsetzung“ werden Performance-Messungen durchgeführt und anschließend analysiert, um einen besseren Vergleich der beiden Cloud-Anbieter in Bezug auf die Performance zu ermöglichen. Es ist ratsam, diese Analysen regelmäßig durchzuführen, um mögliche Leistungsprobleme frühzeitig zu erkennen und zu optimieren.

Die Entscheidung zwischen den Cloud Providern hängt sowohl von den Anforderungen von leoticket als auch von den Präferenzen der Entwickler ab. Wenn Entwickler bereits Erfahrung und Kenntnisse mit einem bestimmten Cloud Provider haben, ist es ratsam, sich für diesen Provider zu entscheiden. Dies bietet den Vorteil, dass man sich nicht in eine neue Technologie einarbeiten muss und Zeit bei der Implementierung und Integration der API sparen kann. Es ist durchaus legitim zu sagen, dass beide Anbieter eine Vielzahl von Funktionen und ähnlichen Produkten anbieten, die an die Anforderungen von leoticket angepasst werden können. Diese Arbeit soll lediglich als Leitfaden dienen, um bei der Entscheidung zu unterstützen und letztendlich eine fundierte Wahl zu treffen.

3 Prototypische Umsetzung

Im folgenden Kapitel wird der Prototyp genauer betrachtet und die verschiedenen Aspekte seiner Entwicklung und Implementierung werden erläutert. Es werden dabei die verwendeten Technologien und die Art der Speicherung und Bereitstellung von Binärdaten beleuchtet. Um die Performance zu bewerten, werden Messungen auf generierte Testdaten durchgeführt. Insgesamt dient das Kapitel als Grundlage für weitere Untersuchungen und die Optimierung des Prototyps.

3.1 Überblick und Vorgehensweise

Zunächst wird auf die eingesetzten Technologien eingegangen, die bei der Entwicklung des Prototyps verwendet werden. Dies umfasst das Framework Spring Boot und Programmiersprachen, die zur Umsetzung des Prototyps genutzt werden. Ein besonderes Augenmerk wird auf die Speicherung der Binärdaten gelegt. Hier werden verschiedene Ansätze betrachtet, wie beispielsweise die Verwendung von AWS SDK und Google Client Libraries. Des Weiteren wird die Bereitstellung der Binärdaten behandelt. Hier wird die Methode der Signed URLs betrachtet, um die Daten effizient an die Anwender zu übertragen. Um die Leistung des Prototyps zu bewerten, werden Testdaten mit zufälligem Inhalt generiert. Dies ermöglicht eine realistische Simulation der Tickets und Rechnungen in leoticket und erlaubt eine Bewertung der Performance der Cloud Provider. Die Messungen werden auf einem virtuellen Server durchgeführt, um eine isolierte Umgebung zu gewährleisten. Dies ermöglicht es, Performance Messungen unabhängig von anderen Prozessen oder Anwendungen auf dem Host-System durchzuführen, ohne Störungen zu verursachen.

3.2 Eingesetzte Technologien

Für die Umsetzung des Prototyps werden die folgenden Technologien eingesetzt:

- Spring Boot v3
- AWS SDK 2.0 Version
- GC Storage client library
- Java SDK 17 Temurin Version
- Apache Maven v3.9.1
- Maven Schema v4.0.0
- AWS Toolkit
- aws cli
- gcloud cli

Für die Implementierung wurde die Entwicklungsumgebung IntelliJ IDEA Ultimate verwendet. IntelliJ bietet ein Plugin namens **AWS Toolkit** an. Als Framework wurde die aktuellste Version von Spring Boot (Version 3) zum Zeitpunkt der Erstellung des Prototyps verwendet. Spring Boot stellt SDKs beider Cloud-Anbieter als Maven-Abhängigkeiten zur Verfügung.

Am 17. März 2021 wurde die neue Version des Spring Cloud AWS 2.3 veröffentlicht. Spring Cloud GCP und Spring Cloud AWS sind nicht mehr Teil des Spring Cloud Releases. Nicht Teil des Releases zu sein bedeutet auch, dass sie aus der Spring Cloud Organisation auf Github herausgenommen worden sind und dadurch neue Maven Package Namen haben. Das neue Package für Spring Cloud AWS heißt nun „io.awspring.cloud“, vgl. ^{spring-cloud-announce}Gibb: Spring Cloud AWS 2.3 is now available, [6].

Die unten aufgeführten Maven Abhängigkeiten werden für AWS S3 und Cloud Storage verwendet:

```
1 <dependency>
2     <groupId>com.google.cloud</groupId>
3     <artifactId>spring-cloud-gcp-starter-storage</artifactId>
4 </dependency>
```

```
1 dependency>
2     <groupId>io.awspring.cloud</groupId>
3     <artifactId>spring-cloud-aws-s3</artifactId>
4     <version>3.0.0</version>
5 </dependency>
```

Als Spring Cloud GCP Version wird die 4.2.0 verwendet. Beide Spring Cloud Abhängigkeiten werden von der Community auf Github verwaltet und aktualisiert. Für die Erstellung des Spring Boot Projekts wurde der Spring Initializier von Spring selbst verwendet unter <https://start.spring.io/>. Zudem wird die Java SDK 17 Temurin Version verwendet. Für Apache Maven wird die 3.9.1 Version verwendet. Für die Authentifizierung wird die **gcloud** cli verwendet. Diese wird über die offizielle Dokumentation installiert. Siehe <https://cloud.google.com/sdk/docs/install?hl=de>. Das AWS Toolkit wird für die Authentifizierung mit AWS angewendet. Um sich mit GC zu verbinden wird eine Methode des ADC verwendet, welches im nächsten Abschnitt genauer erläutert wird.

3.3 Speicherung von Binärdaten

Um Daten in S3 oder Cloud Storage speichern zu können, wurde der Prototyp so implementiert, dass der Nutzer sich zwischen S3 oder Cloud Storage entscheiden kann. Dies geschieht über die Klasse `CloudStorageServiceFactory`. Hier kann der Nutzer über die Umgebungsvariable `cloud_provider` den gewünschten Provider mit `aws` oder `google cloud` angeben. Dabei wird die Groß-, und Kleinschreibung nicht berücksichtigt. Die Umgebungsvariablen können im System durch `export <EnvironmentVariable>=<value>` exportiert werden. Wenn eine IDE wie IntelliJ verwendet wird, kann dies unter den Run-Einstellungen als Umgebungsvariablen eingefügt werden. Nach der Eingabe des Cloud Providers wird das Programm die entsprechende Klasse aufrufen. Für AWS die Klasse `AWSS3StorageService` und für GC die Klasse `GCStorageService`. Beide Klassen implementieren das Interface `CloudStorageService`. Dieses definiert zwei Methoden und eine davon ist für die Speicherung der Daten zuständig:

```
1 void uploadObject(String bucketName, String key, String file, String encryptionKey,
   String storageClass) throws IOException;
```

Dieser Methode wird der Bucket Name, der Name des Objekts, der Pfad des Objekts und der Encryption Key übergeben. Der Encryption Key kann dabei der Schlüssel sein, der in AWS KMS oder GC KMS generiert wurde. Die Implementierung dieser Methode ist für beide Cloud Provider ähnlich gestaltet.

```
1 @Override
2 public void uploadObject(String bucketName, String key, String file, String
   encryptionKey, String storageClass) {
3     try {
4
5         (1) PutObjectRequest putObjectRequest = PutObjectRequest.builder()
6             (2) .bucket(bucketName)
7             (3) .key(key)
8             (4) .serverSideEncryption(ServerSideEncryption.AWS_KMS)
9             (4) .ssekmsKeyId(encryptionKey)
10            (5) .storageClass(storageClass)
11            .build();
12
13        (6) Path filePath = Paths.get(file);
14        (7) byte[] fileBytes = Files.readAllBytes(filePath);
15        (8) RequestBody requestBody = RequestBody.fromBytes(fileBytes);
16
17        (9) this.s3Client.putObject(putObjectRequest, requestBody);
18        logger.info(
19            "File " + file + " uploaded to bucket " + bucketName + " as " + key
20        );
21
22    } catch (S3Exception | IOException e) {
23        logger.error(e.getMessage());
24    }
25 }
```

Listing 3.1: Prototyp Code Snippet - Hochladen eines Objekts nach S3

Der vorliegende Code (3.1) beschreibt den Vorgang des Speicherns eines Objekts in AWS S3. Zunächst wird ein PUT-Request-Objekt erstellt (1), wobei Parameter wie der Bucket-Name (2), der Objektname als Key (3) und die Authentifizierungsmethoden (4) angegeben werden. Dabei wird die AWS KMS-Methode verwendet und der entsprechende Schlüssel bereitgestellt (4). Anschließend wird die Speicherklasse angegeben, in der das Objekt gespeichert werden soll (5). In diesem Beispiel wird die Standard-IA-Klasse verwendet. Danach wird der Pfad der angegebenen Datei gelesen (6), in ein Byte-Array umgewandelt (7) und dem `RequestBody` übergeben (8). Der `RequestBody` wird gemeinsam mit dem `PutObjectRequest` an den `S3Client` übergeben und mit der AWS `.putObject()` Methode in S3 hochgeladen (9). AWS S3 verschlüsselt das Objekt mit dem angegebenen Schlüssel und lädt es in S3 hoch.

Das folgende Code Snippet zeigt die Methode der Klasse `GCStorageService`. Ähnlich wie bei der Methode für AWS S3 wird auch hier ein Objekt nach Cloud Storage hochgeladen:

```
1 @Override
2 public void uploadObject(String bucketName, String key, String file, String
   encryptionKey, String storageClass) throws IOException {
3
4     Map<String, String> kmsKeyName = new HashMap<>();
5     kmsKeyName.put("kmsKeyName", encryptionKey);
6
7     // Get a reference to the bucket
8 (1) BlobId blobId = BlobId.of(bucketName, key);
9 (2) BlobInfo blobInfo = BlobInfo.newBuilder(blobId)
10        .setMetadata(kmsKeyName)
11        .build();
12
13     Storage.BlobWriteOption precondition;
14     if (this.storage.get(bucketName, key) == null) {
15         precondition = Storage.BlobWriteOption.DoesNotExist();
16     } else {
17         precondition =
18             Storage.BlobWriteOption.generationMatch(
19                 this.storage.get(bucketName, key).getGeneration());
20     }
21 (3) this.storage.createFrom(blobInfo, Paths.get(file), precondition);
22
23     logger.info(
24         "File " + file + " uploaded to bucket " + bucketName + " as " + key
25     );
26
27 }
```

Listing 3.2: Prototyp Code Snippet - Hochladen eines Objekts nach Cloud Storage

Dabei werden ähnliche Parameter der Methode wie in AWS S3 übergeben. Um ein Objekt in einen Bucket hochladen zu können, wird eine Referenz zu diesem erstellt. Dies geschieht durch die `BlobId`, welche den Bucket Namen und den Namen des Objekts beinhaltet (1). Anschließend wird diese `blobId` dem `BlobInfo` Objekt übergeben und der Encryption Key über die Metadaten `kmsKeyName` gesetzt (2). Nachdem überprüft worden ist, ob das Objekt bereits im Bucket existiert, wird das Objekt hochgeladen (3).

Um das Programm auszuführen, wird die Hauptklasse `CloudGcStorageAwsS3Application` gestartet. Damit das Programm erfolgreich läuft, müssen die Umgebungsvariablen im System exportiert werden. Alle Umgebungsvariablen sind in der `application.properties` hinterlegt. Diese werden beim Start des Programms gelesen und angewendet. Außerdem müssen die AWS und GC Credentials hinterlegt werden. Dies kann entweder über die AWS Toolkit Plugin gesteuert werden oder in der Kommandozeile mit dem Befehl `aws configure`. Für GC Credentials kann mit dem Befehl: `export GOOGLE_APPLICATION_CREDENTIALS=<service-account-json-file>` der Service Account hinterlegt werden oder durch Ausführen des Befehls `gcloud auth application-default login` in der Kommandozeile, was die Credentials lokal speichert und für ADC verwendet wird.

3.4 Bereitstellung der Binärdaten

Bei der Bereitstellung von Binärdaten in leoticket geht es darum, den Kunden Dateien über Links zugänglich zu machen. Hierfür werden signierte URLs verwendet. Im folgenden Abschnitt werden die Implementierungen und Erläuterungen des entsprechenden Codes von beiden Cloud Providern vorgestellt.

Folgender Code Snippet (3.3) zeigt die Methode zur Generierung einer signierten URL der Klasse **AWSS3StorageService**:

```
1  @Override
2  public URL getPresignedUrl(String bucket, String key, Integer minutes, String
    encryptionKey) {
3      try {
4
5          (1)      GetObjectRequest getObjectRequest =
6                   GetObjectRequest.builder()
7                   (2)          .bucket(bucket)
8                   (3)          .key(key)
9                   .build();
10
11          GetObjectPresignRequest getObjectPresignRequest =
12              GetObjectPresignRequest.builder()
13              (4)          .getObjectRequest(getObjectRequest)
14              (5)          .signatureDuration(Duration.ofMinutes(minutes))
15              .build();
16
17          PresignedGetObjectRequest presignedGetObjectRequest =
18              (6)          presigner.presignGetObject(getObjectPresignRequest);
19
20              (7)      URL url = presignedGetObjectRequest.url();
21
22              logger.info("Presigned URL: " + url);
23
24              return url;
25
26          } catch (S3Exception e) {
27              logger.error(e.getMessage());
28          }
29
30      return null;
31  }
```

Listing 3.3: Prototyp Code Snippet - Generierung einer signierten URL durch AWS

Die Methode erhält ähnlich wie beim Hochladen des Objekts die Parameter Bucket-Name und Objektname. Zudem wird eine Zeitdauer in Minuten übergeben, die festlegt, wie lange der generierte Link gültig sein soll. Für die Entschlüsselung der Daten muss der gleiche Encryption Key wie beim Hochladen verwendet werden. Das **GetObjectRequest** Objekt wird erstellt (1) und mit dem Bucket-Namen (2) und dem Objektnamen (3) versehen. Anschließend wird dieses Objekt an das **GetObjectPresignRequest** Objekt übergeben (4) und die Gültigkeitsdauer der Signatur angegeben (5). Die Gültigkeitsdauer bestimmt, wie lange die signierte URL valide ist. Um die signierte URL zu generieren, wird das **GetObjectPresignRequest** Objekt an den **S3Presigner** übergeben (6), auf welche die Methode **presignGetObject()** aufgerufen wird (6).

Das generierte `PresignedGetObjectRequest` wird als URL gespeichert (7) und ausgegeben.

Folgende Abbildung zeigt die Methode zur Generierung einer signierten URL der Klasse `GCStorageService`:

```
1 @Override
2 public URL getPresignedUrl(String bucketName, String key, Integer minutes, String
   encryptionKey) {
3     try {
4         Map<String, String> kmsKeyName = new HashMap<>();
5         kmsKeyName.put("kmsKeyName", encryptionKey);
6
7         // Define resource
8 (1) BlobInfo blobInfo = BlobInfo.newBuilder(BlobId.of(bucketName, key))
9             .setMetadata(kmsKeyName)
10            .build();
11
12 (2) URL url = this.storage.signUrl(
13 (3)     blobInfo,
14 (4)     minutes,
15         TimeUnit.MINUTES,
16 (5)     Storage.SignUrlOption.withV4Signature()
17     );
18
19     logger.info("Generated GET signed URL: " + url);
20
21 (6)     return url;
22
23     } catch (StorageException e) {
24         logger.error(e.getMessage());
25     }
26
27     return null;
28 }
```

Listing 3.4: Prototyp Code Snippet - Generierung einer signierten URL durch GC

Ähnlich wie bei S3 wird eine Referenz zum Bucket erstellt, indem der Bucket Name und der Name des Objekts dem `BlobInfo` Objekt mitgegeben wird (1). Anschließend kann die URL durch Aufrufen der Methode `.signUrl()` erstellt werden (2). Hier werden die `BlobInfo` Objekt (3), die Minuten (4) und die Signatur Methode (5) übergeben. Zuletzt wird die URL ausgegeben (6).

Mit signierten URLs können die Anforderungen von leoticket an die sichere Speicherung und Bereitstellung der Daten über signierte URLs berücksichtigt werden. Dies bedeutet, Kunden können über diese Links die Dateien für Tickets und Rechnungen herunterladen ohne das Problem von zu großen Email-Anhängen zu haben.

3.5 Messung der Performance

In diesem Abschnitt erfolgt die Messung der Performance für die Dienste von AWS und GC. Dabei werden bis zu 1000 generierte Dateien sowohl für den Upload als auch für den Download betrachtet. Die Performance Analyse wird auf einer virtuellen Maschine in der Hetzner Cloud ausgeführt, um eine isolierte Umgebung zu gewährleisten. Die Performance-Messung beim Hoch- und Herunterladen kann jedoch von verschiedenen Faktoren wie Netzwerklatenz, verfügbarer Bandbreite, Serverkapazität, Datenmenge und der Auslastung der Server beeinflusst werden. Außerdem kann der Hetzner Server näher an AWS oder GC liegen und dies könnte dazu führen, dass die Dauer des Hoch-, und Herunterladens aus diesem Grund schneller ist. Die Messungen dienen lediglich dem groben Vergleich beider Cloud Provider. Die Performance-Messung wird auf verschiedene Speicherklassen durchgeführt, um einen Vergleich zwischen diesen zu ermöglichen und eine Grundlage für die Bewertung ihrer Leistungsfähigkeit zu schaffen.

AWS

AWS bietet Dienste für die Performance Analyse. Unter anderem die Amazon CloudWatch, S3 Storage Lens und die S3 Transfer Acceleration. Die AWS CLI stellt einfache Methoden zum S3 Upload und Download Tests vor. Beispielsweise kann man mit dem Befehl:

```
1 aws s3 cp <lokaler_pfad> s3://<Bucket_Name>/<Ziel_Dateipfad>
```

Dateien hoch-,und herunterladen und die Zeit für die benötigte Request messen. Auch mit der AWS SDK können Performance Test Skripte geschrieben werden. Diese Methode wird für den Prototypen angewendet. Dabei werden Tests bereitgestellt, die mehrere Dateien automatisch hoch-, und herunterladen und dabei die vergangene Zeit messen.

GC Storage

GC bietet ein eigenes `gsutil` Tool für die Performance Analyse. Wie im Abschnitt Performance bereits erwähnt, können durch die `perfdiag` Funktion Performance Diagnosen erstellt werden.

Mehrere Testdateien werden aus einem angegebenen Bucket hoch-, und heruntergeladen. Nach der Analyse werden alle Testdateien nach erfolgreicher Diagnose gelöscht. Die `gsutil` Performance kann von einigen Faktoren wie vom Client, Server oder Netzwerk beeinflusst werden. Möglich sind die CPU Dauer, der verfügbare Speicher, die Netzwerk Bandbreite, Firewalls und Fehlerraten zwischen `gsutil` und den Google Servern. Die `perfdiag` Funktion wurde bereitgestellt, damit Nutzer Messungen durchführen können, die beim Troubleshooting von Performance Problemen helfen, vgl. [gc-perfdiag](#) Storage: `perfdiag` - Run performance diagnostic, [18].

Um die Performance Diagnose auszuführen, kann der folgende Befehl verwendet werden:

```
1 gsutil perfdiag -o test.json -n 67000 -s 400kb gs://leoticket-bucket
```

Die `-o` Option schreibt den Output des Ergebnisses in eine Datei. Die Output Datei ist eine JSON Datei mit System Informationen und enthält die Performance Diagnose Ergebnisse. Die `-n` Option setzt die Anzahl der Objekte, die heruntergeladen und hochgeladen werden sollen während des Tests. Mit der `-s` Option kann man die Objektgröße in bytes angeben. Zum Schluss wird der Name

des Buckets angegeben.

Um die Performance der SDKs zu analysieren, werden Objekte mit jeweils 100kb Objektgröße in verschiedenen Speicherklassen hoch-, und heruntergeladen. Anschließend wird die Performance über das SDK von Cloud Storage ähnlich wie bei AWS getestet. Der Test wird ebenfalls auf einer virtuellen Maschine von Hetzner ausgeführt.

Die Performance wird in Zehner-Vielfachen gemessen, beginnend mit einer Datei bis hin zu 1000 Dateien. Dies bedeutet, dass Messungen für eine Datei, zehn Dateien, 100 Dateien und 1000 Dateien durchgeführt werden. Zur Durchführung der Messung wird eine Java Jar-Datei des Prototyps erstellt, in der die Testmethoden ausgeführt werden. Diese Testmethoden generieren zunächst Testdaten, die mit zufälligen String-Werten der Größe 100 KB gefüllt sind. Anschließend werden die Testmethoden in der Kommandozeile ausgeführt.

3.5.1 Messungsergebnisse

In diesem Abschnitt werden die Messungsergebnisse der Performance Messung in Millisekunden-Zahlen präsentiert. Die Speicherklassen Standard, Standard-IA und One Zone-IA von AWS wurden jeweils mit Standard, Nearline und Coldline von GC verglichen. Im Folgenden werden die Ergebnisse der Upload und Download Dauer aller Speicherklassen präsentiert:

STANDARD-IA vs. NEARLINE

1 File-----

Elapsed Time for 1 Object Upload in S3:-----705ms.

Elapsed Time for 1 Object Upload in Cloud Storage:-----841ms.

Elapsed Time for 1 Object Download in S3:-----18ms.

Elapsed Time for 1 Object Download in Cloud Storage:-----26ms.

10 Files-----

Elapsed Time for 10 Object Uploads in S3:-----1862ms.

Elapsed Time for 10 Object Uploads in Cloud Storage:-----3217ms.

Elapsed Time for 10 Object Downloads in S3:-----35ms.

Elapsed Time for 10 Object Downloads in Cloud Storage:-----94ms.

100 Files-----

Elapsed Time for 100 Object Uploads in S3:-----16681ms.

Elapsed Time for 100 Object Uploads in Cloud Storage:-----22683ms.

Elapsed Time for 100 Object Downloads in S3:-----129ms.

Elapsed Time for 100 Object Downloads in Cloud Storage:-----269ms.

1000 Files-----

Elapsed Time for 1000 Object Uploads in S3:-----71175ms.

Elapsed Time for 1000 Object Uploads in Cloud Storage:-----1851348ms.

Elapsed Time for 1000 Object Downloads in S3:-----663ms.

Elapsed Time for 1000 Object Downloads in Cloud Storage:-----1489ms.

STANDARD vs. STANDARD

1 File-----

Elapsed Time for 1 Object Upload in S3:-----585ms.

Elapsed Time for 1 Object Upload in Cloud Storage:-----660ms.

Elapsed Time for 1 Object Download in S3:-----28ms.

Elapsed Time for 1 Object Download in Cloud Storage:-----19ms.

10 Files-----

Elapsed Time for 10 Object Uploads in S3:-----1369ms.

Elapsed Time for 10 Object Uploads in Cloud Storage:-----3002ms.

Elapsed Time for 10 Object Downloads in S3:-----70ms.

Elapsed Time for 10 Object Downloads in Cloud Storage:-----108ms.

100 Files-----

Elapsed Time for 100 Object Uploads in S3:-----8110ms.

Elapsed Time for 100 Object Uploads in Cloud Storage:-----20750ms.

Elapsed Time for 100 Object Downloads in S3:-----180ms.

Elapsed Time for 100 Object Downloads in Cloud Storage:-----396ms.

1000 Files-----

Elapsed Time for 1000 Object Uploads in S3:-----73992ms.

Elapsed Time for 1000 Object Uploads in Cloud Storage:-----176004ms.

Elapsed Time for 1000 Object Downloads in S3:-----650ms.

Elapsed Time for 1000 Object Downloads in Cloud Storage:-----1619ms.

ONEZONE-IA vs. COLDLINE

1 File-----

Elapsed Time for 1 Object Upload in S3:-----505ms.

Elapsed Time for 1 Object Upload in Cloud Storage:-----636ms.

Elapsed Time for 1 Object Download in S3:-----28ms.

Elapsed Time for 1 Object Download in Cloud Storage:-----18ms.

10 Files-----

Elapsed Time for 10 Object Uploads in S3:-----1105ms.

Elapsed Time for 10 Object Uploads in Cloud Storage:-----2855ms.

Elapsed Time for 10 Object Downloads in S3:-----65ms.

Elapsed Time for 10 Object Downloads in Cloud Storage:-----89ms.

100 Files-----

Elapsed Time for 100 Object Uploads in S3:-----7539ms.

Elapsed Time for 100 Object Uploads in Cloud Storage:-----20391ms.

Elapsed Time for 100 Object Downloads in S3:-----187ms.

Elapsed Time for 100 Object Downloads in Cloud Storage:-----250ms.

1000 Files-----

Elapsed Time for 1000 Object Uploads in S3:-----73086ms.

Elapsed Time for 1000 Object Uploads in Cloud Storage:-----163661ms.

Elapsed Time for 1000 Object Downloads in S3:-----701ms.

Elapsed Time for 1000 Object Downloads in Cloud Storage:-----1559ms.

Die Ergebnisse werden im Kapitel Zusammenfassung der Ergebnisse untersucht und dargestellt.

3.6 Zusammenfassung der Implementierung

Der Prototyp soll einen Vergleich zwischen den beiden Cloud Providern bieten. Das Ziel dabei ist es, ähnliche Technologien von beiden Providern zu verwenden und die Performance mit Testdaten messen zu können.

Der Prototyp implementiert zwei wichtige Funktionen: Das Hochladen und Herunterladen von Dateien unter Berücksichtigung der Anforderungen von leoticket. Dabei werden signierte URLs zur Bereitstellung der Dateien verwendet und die SSE KMS von beiden Providern für die Datenverschlüsselung angewendet. Der Prototyp soll auch als externe Bibliothek für eigene Anwendungen integriert werden können. Bei der Implementierung wurden die offiziellen Dokumentationen von AWS und Google Cloud verwendet, um die aktuellsten Versionen zum Zeitpunkt der Arbeit zu verwenden. Auf Wunsch von Leomedia wurde Spring Boot als Framework gewählt, um eine Enterprise-Anwendung bereitzustellen. Java wurde aus Präferenzgründen als Programmiersprache gewählt, obwohl beide Provider viele weitere Sprachen, die bereits im Kapitel zur API-Anbindung erwähnt wurden, unterstützen.

Der Prototyp umfasst eine Implementierung, die es ermöglicht, über eine Umgebungsvariable zwischen AWS und GC zu wählen. Die Klasse `CloudStorageServiceFactory` stellt die Auswahl zwischen AWS und GC zur Verfügung. Je nachdem welchen Cloud Provider der Nutzer angegeben hat, wird die entsprechende Klasse instanziiert und aufgerufen. Die Klassen `AWSS3StorageService` und `GCStorageService` implementieren die Methoden des Interfaces `CloudStorageService`.

Die bereitgestellten Tests dienen der Performance Messung. Dabei werden Dateien automatisch als 100kb große Objekte erstellt und durch die Testmethoden verwendet, um Objekte hoch-, und herunterzuladen. Sie unterstützen dabei, die Dauer der verschiedenen Funktionen zu messen.

Da die Maven Abhängigkeiten kein Teil der Spring Cloud Release Train sind, hängt es von der Community ab, die Versionen aktuell zu halten. Für AWS bedeutet dies, dass die AWS SDK 2.0 Version nicht komplett abgedeckt ist. Jedoch ist sie so weit, dass S3 bereits unterstützt wird.

4 Ergebnisse dieser Arbeit

In diesem Kapitel werden die Funktionalitäten des Prototyps beschrieben. Zum Schluss werden die Kalkulationsergebnisse der Kostenanalyse als Tabelle und die Messungsergebnisse der Performance Messung als Liniendiagramm bereitgestellt und auf einzelne Ergebnisse eingegangen. Außerdem dient dieses Kapitel zur kurzen Übersicht über die Ergebnisse der Performance und Kosten.

4.1 Beschreibung und Funktionalität des Prototyps

Der Prototyp hat die Funktionalität des Uploads und Downloads von Objekten nach S3 oder Cloud Storage. Der Nutzer kann sich zwischen AWS und GC entscheiden, indem die `cloud_provider` Umgebungsvariable vor dem Ausführen des Programms gesetzt wird. Damit das Programm erfolgreich durchlaufen kann, müssen alle Umgebungsvariablen in der `application.properties` Datei gesetzt werden. Außerdem wird eine Authentifizierung für GC und AWS verlangt, sonst schlägt das Programm fehl. Die Authentifizierung für GC kann über die ADC erfolgen. In der offiziellen Dokumentation werden die verschiedenen Methoden aufgelistet. Für den Prototypen wurde die lokale Entwicklungsumgebung für die Authentifizierung durch:

```
1 export GOOGLE_APPLICATION_CREDENTIALS=<jsonKeyPath>
```

oder durch den `gcloud cli` Befehl:

```
1 gcloud auth application-default login
```

verwendet. Dabei ist der `jsonKeyPath` der Pfad zum erstellten Service Account, welche Rechte für das Uploaden und Downloaden besitzt. Unter <https://cloud.google.com/docs/authentication/provide-credentials-adc> können die ADC Credentials Methoden eingesehen werden.

Für die Authentifizierung mit AWS benötigt es lediglich das AWS Toolkit Plugin. Dieses stellt AWS für einige IDEs zur Verfügung. Unter anderem für Visual Studio, Eclipse und JetBrains Idea. Falls das AWS Toolkit nicht zur Verfügung steht, kann die Authentifizierung auch über die `aws cli` erfolgen. Durch `aws configure` können die Credentials gesetzt werden. Unter <https://docs.aws.amazon.com/sdk-for-java/latest/developer-guide/setup-basics.html> können die AWS Credentials Methoden eingesehen werden. Nachdem die Authentifizierungseinstellungen und die Umgebungsvariablen gesetzt wurden, kann das Programm gestartet werden. Damit die Dateien in der richtigen Speicherklasse hochgeladen werden, muss für GC der korrekte Bucket Name angegeben werden. In AWS muss jedoch die gewünschte Speicherklasse angegeben werden, damit das Objekt in diese geschrieben wird. Dieser Unterschied besteht, da in GC die Speicherklasse über die GC Konsole für ein Bucket ausgewählt werden kann. In AWS ist dies jedoch nicht möglich, deshalb haben alle Buckets in AWS bei Erstellung die Standard Speicherklasse eingestellt. Die Objektklasse muss speziell durch den Parameter `storageClass` beim Hochladen angegeben werden. Das Objekt wird durch die SSE KMS verschlüsselt hochgeladen. Die Verschlüsselung wird automatisch von beiden Cloud Providern durchgeführt. Dabei muss der entsprechende KMS Schlüssel des ausgewählten Cloud Providers der Environment Variable `sse_kms_key_id_arn` übergeben werden. Beim Herunterladen des Objekts muss dieser Schlüssel erneut mitgegeben werden, da-

mit das Objekt entschlüsselt werden kann. Die Hauptklasse `HandsonAwsGcApplication` ruft die entsprechende Klasse für AWS oder GC auf und initialisiert diese. Vorher müssen die Parameter für die `.uploadObject(bucketName, key, filePath, encryptionKey, storageClass)` und `.getPresignedUrl(bucketName, key, minutes, encryptionKey)` übergeben werden. Die Minuten stellen die Zeit ein, in der die generierte signierte URL gültig ist. Der `storageClass` Parameter gilt nur für die AWS Funktion und kann die Werte `STANDARD`, `STANDARD_IA` und `ONEZONE_IA` annehmen.

Über Terraform werden die Buckets erstellt und die Konfigurationen eingestellt. Diese Konfigurationen sind an die Anforderungen an leoticket angepasst. Die Buckets müssen vor dem Programmstart bereits existieren, deshalb muss die Terraform Datei am Anfang durchlaufen. Die Terraform Dateien werden im entsprechenden Ordner bereitgestellt. Diese werden vor dem Programmstart als erstes ausgeführt, um die benötigten Ressourcen zu erstellen.

Der Prototyp dient außerdem dazu, die APIs miteinander zu vergleichen und jeweils ähnliche Funktionalitäten für beide Provider bereitzustellen.

4.2 Zusammenfassung der Ergebnisse

In diesem Abschnitt werden die Kosten der verschiedenen Speicherklassen nochmal aufgegriffen und die Gesamtkosten als Tabelle dargestellt. Auch werden die Messungsergebnisse der Performance Analyse als Liniendiagramm bereitgestellt und die Zahlen der Kosten und Messungen untersucht.

4.2.1 Kalkulationsergebnisse

Im folgenden werden die Gesamtkosten der Speicherklasse von beiden Cloud Providern dargestellt und untersucht. Zuerst werden in der unteren Tabelle die Kosten von AWS untersucht:

	Standard	Intelligent Tiering	Standard-IA	One Zone-IA
Monatliche Speicherkosten	70.27 EUR	70.27 EUR	38.72 EUR	30.98 EUR
PUT Requests	1.35 EUR	1.35 EUR	2.50 EUR	2.50 EUR
GET Requests	0.22 EUR	0.22 EUR	0.50 EUR	0.50 EUR
Datenabrufe	–	–	0.47 EUR	0.47 EUR
Data Transfer	4.20 EUR			
Monitoring und Automation objects	–	75.19 EUR	–	–
Gesamtkosten pro Monat(ohne Vorauszahlung)	76.04 EUR	151.23 EUR	46.39 EUR	38.65 EUR
Vorauszahlung	162.42 EUR	162.42 EUR	300.76 EUR	300.76 EUR
Gesamtkosten im ersten Monat	238.46 EUR	313.65 EUR	347.15 EUR	339.41 EUR

Tabelle 4.2.1: Zusammenfassung der Gesamtkosten für AWS S3 pro Speicherklasse

In dieser Abbildung werden in der letzten Zeile der Tabelle die Gesamtkosten der Speicherklassen pro Monat veranschaulicht. Die Gesamtkosten im ersten Monat der Speicherklasse Standard beträgt 123.67 USD. In diesen Kosten stecken die Vorauszahlungskosten, die PUT und GET Request Gebühren und die Datenübertragungsgebühren. Im Intelligent Tiering und Standard sind die Datenabrufgebühren nicht enthalten, da dafür keine Gebühren abgezogen werden. Die Gesamtkosten des Intelligent Tiering pro Monat beträgt 120.15 USD. Die Kosten des Intelligent Tiering hängen jedoch von der Speicherverteilung ab. Die Kosten sind grobe Werte und können von der Verteilung des Speichers in verschiedene Speicherklassen in Prozent abhängen. Bei der Standard-IA Speicherklasse sind es mit 127.81 USD Kosten die teuersten Kosten im Vergleich zu den anderen Speicherklassen. Die One Zone-IA ist mit 119.51 USD die billigste Speicherklasse.

In Google Cloud gibt es keine Vorauszahlungen im Vergleich zu AWS. Hier unterscheiden sich die Gesamtkosten der verschiedenen Speicherklassen zu AWS. In der folgenden Tabelle werden die Gesamtkosten zusammengefasst:

	Standard	Nearline	Coldline
Monatliche Speicherkosten	63.75 EUR	36.03 EUR	16.63 EUR
Datenabrufe	–	0.45 EUR	0.90 EUR
Klasse A Operationen	1.21 EUR	2.42 EUR	4.84 EUR
Klasse B Operationen	0.19 EUR	0.48 EUR	4.84 EUR
Internet Egress monatlich	3.83 EUR pro 0 bis 1TB		
Gesamtkosten pro Monat	68.98 EUR	43.21 EUR	31.04 EUR

Tabelle 4.2.2: Zusammenfassung der Gesamtkosten für GC Storage pro Speicherklasse

Die Gesamtkosten bilden sich hauptsächlich aus den Datenabrufen, Class A und Class B Operationen, welche PUT und GET Operationen beinhalten und die Internet Egress, ausgehend von GC zum Internet, beispielsweise beim Abrufen von Dateien. Es fallen keine Gebühren für die Datenabrufe der Standard Speicherklasse an. Die Gesamtkosten des Standards beträgt 69.86 Euro, der Nearline 42.61 Euro und des Coldline 25.36 Euro.

4.2.2 Messergebnisse

In diesem Abschnitt werden die Messergebnisse der Performance Analyse bereitgestellt. Die Speicherklassen Standard, Standard-IA und One Zone-IA von AWS wurden jeweils mit Standard, Nearline und Coldline von GC verglichen. Im folgenden werden die Ergebnisse der Upload Dauer aller Speicherklassen als Liniendiagramm dargestellt:




Abbildung 4.2.1: Upload Zeit der verschiedenen Speicherklassen

Die X-Achse beschreibt die Objektanzahl, die für jede Speicherklasse hochgeladen wurde. Die Farben unterscheiden die verschiedenen Speicherklassen, wobei die Speicherklassen von AWS jeweils nebeneinander platziert sind, genauso wie die Speicherklassen von GC. Die Zahlen vom Abschnitt 3.5.1 wurden in diesen Diagramm eingefügt, um die Unterschiede zwischen den Speicherklassen beider Provider zu visualisieren. So liegen die Speicherklassen von AWS im Graph nah beieinander, ähnlich wie jene von GC. Beim Hochladen von einer Datei bis hin zu zehn Dateien gibt es minimale Unterschiede. Diese Werte liegen unter 3 Sekunden. Die Linien gehen ab dem Hochladen von 11 bis 1000 Dateien stärker auseinander. Die drei Speicherklassen von GC entfernen sich von den drei Speicherklassen von AWS. Ab 100 Dateien gibt es erneut einen Knick und die Speicherklassen von GC entfernen sich weiter von den AWS Speicherklassen. Die GC Speicherklassen wachsen steiler nach oben als bei AWS und bewegen sich in höheren Sekunden Bereichen von ungefähr 20 bis hin zu 190 Sekunden. AWS bewegt sich dabei maximal bis 140 Sekunden.

Bei der Dauer des Downloads unterscheiden sich die Werte vom Upload stärker, denn die Zahlen für den Download bewegen sich in Bereichen von 16 bis hin zu 1556 Millisekunden. Hier steigen die Werte nicht höher als 2 Sekunden. In der folgenden Abbildung wird dies veranschaulicht:

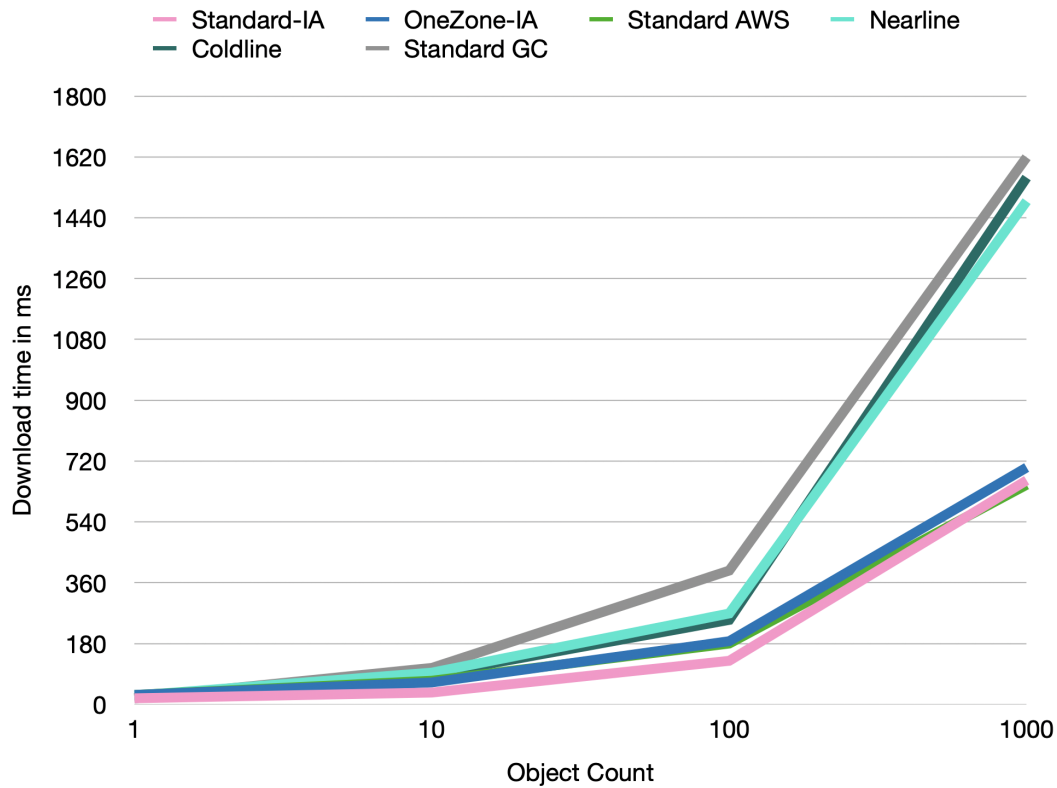


Abbildung 4.2.2: Download Zeit der verschiedenen Speicherklassen

Dieser Graph ähnelt dem Graph des Uploads in Abbildung 4.2.3. Denn auch hier entfernen sich die Linien der GC Speicherklassen von den AWS Speicherklassen. Ab Downloads von zehn Dateien trennen sich die Cloud Provider voneinander. Die Coldline Speicherkategorie von GC hat dabei am längsten mit 1556 Millisekunden für den Download von 1000 Dateien gebraucht. Die schnellste Speicherkategorie von AWS ist die OneZone-IA mit 569 Millisekunden beim Download von 1000 Dateien. Wobei die Speicherkategorien von AWS nah beieinander liegen und weniger als 1 Sekunde für den Download gebraucht haben. Bei GC dauern die Downloads von 1000 Dateien mindestens 1500 Millisekunden. Im Bereich von einer bis zehn Dateien bewegen sich die Speicherkategorien in unter 160 Millisekunden Bereichen. Jedoch gibt es bei zehn Dateien bereits erste minimale Unterschiede, die langsam wachsen.

5 Diskussion

In diesem Kapitel werden die Kalkulations-, und Messergebnisse der Performance analysiert und interpretiert. Anschließend wird der Prototyp bewertet und dabei auf dessen Grenzen eingegangen.

5.1 Analyse und Interpretation der Ergebnisse

Basierend auf der Kostenanalyse und den Ergebnissen der Kalkulation ergibt sich, dass die Speicherklassen OneZone-IA von AWS und Coldline von GC die niedrigsten Kosten für die Speicherung von Daten aufweisen. Jedoch sind Datenabrufe in diesen Speicherklassen als kostenintensiv zu betrachten. In der Coldline-Klasse belaufen sich die Kosten für Class A- und Class B-Operationen jeweils auf 4,84 Euro, während bei AWS PUT-Anfragen, die mit Class A gleichzusetzen sind, 2,50 Euro und GET-Anfragen, die mit Class B gleichzusetzen sind, 0,50 Euro betragen. Insgesamt sind die Kosten für die Coldline-Klasse im Vergleich zur OneZone-IA-Klasse jedoch günstiger.

Die Entscheidung für OneZone-IA als Speicherklasse birgt das Risiko auf das Nicht-zugreifen von Daten bei Ausfall der AZ, da die Daten nur in einer Verfügbarkeitszone gespeichert werden. Dies steht im Widerspruch zu den Anforderungen von leoticket an eine hohe Verfügbarkeit. Obwohl die Speicherkosten in dieser Klasse am niedrigsten sind, sind die Kosten für Datenabrufe im Vergleich zu anderen Speicherklassen höher. Für leoticket ist es jedoch von Bedeutung, auf Objekte mindestens zweimal zugreifen zu können und sie den Kunden zur Verfügung zu stellen. Bei älteren Daten, die mehrere Jahre zurückliegen, kann es ratsam sein, die Objekte in die OneZone-IA zu verschieben, um Kosten für die Archivierung einzusparen.

Die Verfügbarkeit der Coldline-Klasse ähnelt der OneZone-IA-Klasse. Die Datenabrufe in dieser Klasse können mehrere Stunden dauern. Sie ist nicht für Szenarien geeignet, die einen sofortigen Zugriff auf Daten erfordern oder in denen häufiger auf die Daten zugegriffen werden muss. Im Gegensatz zur OneZone-IA ist die Coldline-Klasse jedoch nicht auf eine einzelne Verfügbarkeitszone beschränkt. Aufgrund ihrer günstigeren Kosten und der Verfügbarkeit in mehreren Availability Zones ist Coldline die bessere Option für die langfristige Archivierung von Daten. Da die Kosten für Datenabrufe in dieser Klasse höher sind als in allen anderen Speicherklassen, ist sie nicht geeignet für Daten, auf die mehr als einmal zugegriffen werden muss.

Im Rahmen der Performance-Analyse zeigte die OneZone-IA-Klasse eine bessere Leistung als die Coldline-Klasse. Bereits ab dem Upload von 10 Dateien war die OneZone-IA-Klasse deutlich schneller. In diesem Szenario war sie doppelt so schnell wie die Coldline-Klasse. Ab 100 Dateien wurde ein Unterschied von fast 13 Sekunden festgestellt, wobei die Coldline-Klasse etwa 20 Sekunden und die OneZone-IA-Klasse nur etwa sieben Sekunden benötigte. Bei 1000 Dateien bewegten sich beide Speicherklassen im Minutenbereich, wobei auch hier die OneZone-IA-Klasse doppelt so schnell war wie die Coldline-Klasse. Beim Download von Dateien bewegten sich beide Klassen in Millisekunden Bereichen. Ab 1000 Dateien lag die Coldline-Klasse im Sekundenbereich, während die OneZone-

IA-Klasse weniger als eine Sekunde benötigte.

Die Speicherklassen Standard-IA und Nearline weisen nur geringfügige Preisunterschiede auf, die sich auf maximal zwei Euro belaufen. Dabei ist Nearline maximal zwei Euro günstiger als Standard-IA. Die Standard-IA eignet sich für seltene Datenabrufe, die jedoch eine schnellere Zugriffszeit erfordern, wenn sie benötigt werden. Die Nearline-Klasse ähnelt der Standard-IA und ist ebenfalls für Daten gedacht, die gelegentlich im Zeitraum von Wochen oder Monaten abgerufen werden. Sie ist ideal für Datensicherung, Datenmigration und Datenarchivierung. Beide Speicherklassen bieten einen Kompromiss zwischen Kosteneinsparungen und Datenzugriffszeiten.

Während der Performance Analyse wurden diese beiden Speicherklassen verglichen, da sie ähnliche Eigenschaften aufweisen. Es stellte sich heraus, dass sich die Dauer des Uploads und Downloads erst ab 10 Dateien zu unterscheiden began. Dabei war die Standard-IA beim Hochladen und Herunterladen der zehn Dateien fast dreimal so schnell wie die Nearline-Klasse. Die Nearline-Klasse schnitt beim Hochladen schlechter ab. Beim Herunterladen von Dateien gab es jedoch nur minimale Unterschiede, wobei sich Nearline bei 1000 Dateien im Sekundenbereich und die Standard-IA unter eine Sekunde bewegten.

Die Standardklassen beider Anbieter weisen kaum Unterschiede bei den PUT- und GET-Anfragen auf. Allerdings sind die Speicherkosten in der Standardklasse von AWS höher als bei GC. Beide Klassen eignen sich für Daten, auf die häufig zugegriffen wird und die eine hohe Verfügbarkeit, schnelle Zugriffszeiten und geringe Latenzzeiten erfordern. Beide Standardklassen sind für den allgemeinen Gebrauch optimiert, wobei die Speicherkosten in diesen Klassen im Vergleich zu anderen Speicherklassen am höchsten sind.

Bei der Performance-Analyse schnitt die Standardklasse von AWS ab zehn Dateien besser ab als die entsprechende Klasse von GC. Beim Hochladen von Dateien war die AWS-Standardklasse etwa dreimal schneller als die GC-Standardklasse. Beim Herunterladen von Dateien waren die Unterschiede nicht groß genug, um eine eindeutige Aussage über die Überlegenheit einer Klasse zu treffen. Allerdings bewegte sich auch hier die GC-Standardklasse ab 1000 Dateien bereits im Sekundenbereich, während die AWS-Standardklasse im Millisekundenbereich blieb.

Es ist anzumerken, dass bei den AWS Kosten auch die Vorabzahlung der Speicherung aller Objekte enthalten ist. Bei GC gibt es hingegen keine Vorauszahlung für die Speicherung von Objekten. Aus diesem Grund und auch durch die niedrigeren Gebühren der Speicherung ist GC die kostengünstigere Datenspeicherung.

Insgesamt war die Dauer des Uploads und Downloads der Speicherklassen von AWS in der Performance-Analyse höher als bei GC. Ab einer Datei traten bereits erste Unterschiede auf, wobei GC mehr Zeit in Anspruch nahm. Die Performance-Messungen basieren jedoch lediglich auf groben Schätzungen innerhalb einer virtuellen Umgebung. Faktoren wie die Auslastung des Netzwerks können die Ergebnisse beeinflussen und stellen keine aussagekräftigen Performance-Ergebnisse dar.

5.2 Bewertung des Prototyps

Für die Bewertung des Prototyps wurden die Anforderungen von leoticket herangezogen. Dabei war es wichtig, den Prototypen so zu bauen, dass die sichere Speicherung gedeckt war. Für die Deckung der sicheren Speicherung wurden verschiedene Methoden betrachtet, die beide Cloud Provider anboten. Dabei implementiert der Prototyp die SSE-KMS Methode beider Provider. Durch die eigene Erstellung des Schlüssels in der KMS von AWS und GC hat der Nutzer mehr Kontrolle, indem die Schlüssel vom Nutzer erstellt werden. Der Schlüssel wird vom KMS gespeichert und muss daher nicht vom Nutzer extern gespeichert und verwaltet werden. Der Prototyp kann jedoch so umgebaut werden, sodass auch eine andere Methode wie die SSE-C verwendet werden kann. Die SSE-C bietet eine höhere Sicherheit, da der Nutzer den Schlüssel selber generieren und speichern muss. Dies führt auch zum Risiko, den Schlüssel zu verlieren. In diesem Fall kann auf die Objekte im Bucket nicht mehr zugegriffen. Noch ein Kriterium von leoticket war die hohe Verfügbarkeit der Daten. Der Prototyp wurde so gebaut, dass der Nutzer die Speicherklasse für AWS selbst wählen kann. In GC funktioniert das, indem das Bucket die richtige Speicherklasse bereits eingestellt hat. Für die Verfügbarkeit sind jedoch die Cloud Provider verantwortlich. Hier versprechen beide Provider eine Verfügbarkeit von mindestens 99.5%. Diese Verfügbarkeit hängt von den verschiedenen Speicherklassen ab. Über Terraform werden Buckets automatisch mit den Einstellungen konform zu den Anforderungen von leoticket erstellt. Dies beinhalten die Konfigurationen von:

- Object Versioning
- Lifecycle Rules
- Object Ownership
- Data Encryption
- Object Logging
- Bucket ACL
- Public Access Block

Die Objekt Versionierung dient zur Steigerung der Verfügbarkeit, falls Daten unerwünscht gelöscht oder überschrieben werden. Für die Anforderung der Integration in Software-Produkten wie leoticket sorgen die SDKs der beiden Provider. Die SDKs unterstützen verschiedene Programmiersprachen. Sie werden auch als Maven Abhängigkeiten in einer Spring Boot Applikation unterstützt und auch außerhalb Spring Boot. Die Anbindung verläuft in einfachen Schritten durch Befolgen der offiziellen Dokumentation der beiden Cloud Providern. Die Dokumentationen sind gepflegt und sorgen für die Bereitstellung der nötigen Informationen, um Dateien nach Buckets hoch-, und herunterzuladen. AWS und GC bieten auch neue Versionen an und updaten die SDKs. Die Generierung der signierten URLs sind für die Bereitstellung der Dateien zuständig. Diese Anforderung war das Hauptmerkmal von leoticket. Dabei ist es bei beiden Providern möglich signierte zeitlich begrenzte URLs zu generieren und diese Nutzern bereitzustellen, ohne ein AWS oder GC Konto zu haben. Besitzer der URL können so ihre Tickets und Rechnungen herunterladen. Um die Methoden des Prototyps zu testen, werden Tests bereitgestellt, die Buckets mocken und so Dateien hoch-, und herunterladen können. Für die Performance Analyse wird eine Methode zur Verfügung gestellt, die Testdateien in Größe von 100kb erstellen und in Buckets hoch-, und herunterladen

können.

Insgesamt ist der Prototyp ausbaufähig und stellt für diese Arbeit einen Handson dar. Für den besseren Vergleich der beiden Cloud Provider wurden die Technologien ausprobiert und umgesetzt. Durch Änderungen an der Konfiguration in Terraform, die Speicherklassen Variable für AWS und an der Methode der Datenverschlüsselung kann der Prototyp nach Wünschen angepasst werden. Die Schwächend es Prototyps besteht darin, dass keine genauen Performance Messungen durchgeführt werden können durch die genannten Faktoren, die die Ergebnisse beeinflussen können. Es dient lediglich des groben Vergleichs. Eine weitere Schwäche des Prototyps besteht darin, dass Entwickler bei der Integration des Prototyps in eigene Anwendungen Anpassungen durchführen müssen, indem die Hauptklasse des Prototyps so umgebaut werden muss, dass das gewünschte Verhalten läuft.

6 Fazit

In diesem Kapitel werden die zuvor gestellten Fragen beantwortet, um den roten Faden der Arbeit nochmals deutlich herauszustellen. Darüber hinaus wird die potenzielle Anwendung des Prototyps diskutiert.

6.1 Beantwortung der Forschungsfrage

Um die gestellten Fragen zu beantworten, werden sie zunächst aufgegriffen. Folgende Fragen wurden am Anfang der Arbeit gestellt:

- Welches Speichersystem ist im Hinblick auf Kosten, Performance und Verfügbarkeit für die Persistenz von Binärdaten besonders geeignet?
- Wie können Daten durch sichere, zeitlich begrenzte URL's bereitgestellt werden?

Um die erste Frage zu beantworten, werden die Punkte vom theoretischen Teil aufgegriffen. Es wurden verschiedene Speicherarten wie Objekt-, Block-, und File Storage untersucht. Dabei stellte sich heraus, dass Objekt Storage als Speichersystem für die Anforderungen von leoticket geeignet ist. Einige Cloud Provider stellen Objekt Storage zur Speicherung von Daten zur Verfügung und ist im aktuellen Markt stark vertreten. Es wurden die zwei größten Cloud Provider AWS und GCP betrachtet und eine Vergleichsbasis hergestellt in Hinblick auf Kosten, Performance, Verfügbarkeit, Sicherheit, Bereitstellung der Daten und API Anbindungen. Bei der sicheren Speicherung war es wichtig, dass die Daten vertraulich gespeichert werden und nur berechtigter Zugriff auf die Daten haben.

Datenverschlüsselungsmethoden wurden bei beiden Cloud Providern betrachtet und dabei festgestellt, dass die SSE C zwar die stärkste, unabhängige Sicherheit bietet, jedoch das Risiko besteht, selbstverwaltete und gespeicherte Schlüssel zu verlieren. Außerdem müssten Mitarbeiter dafür geschult werden, was extra Aufwand bedeutet. Aus diesem Grund wurde für die Implementierung des Prototyps die SSE-KMS customer-managed Methode verwendet, damit der Nutzer die Schlüssel in der KMS von den Providern selber erstellen und verwalten kann. So bleibt die Kontrolle noch und verschafft höhere Sicherheit. Bei der Verfügbarkeit versprechen beide Provider eine Verfügbarkeit von 99.9% und hängt von den Speicherklassen ab, für die man sich entscheidet. Bei der Untersuchung der Speicherklassen in Verbindung mit Kosten und Performance stellte sich heraus, dass die Standard-IA von AWS und die Nearline von GC besser zu den Anforderungen von leoticket passt. Da die Latenz für leoticket kein Kriterium darstellt und vernachlässigt werden kann, fallen die Standard Klassen beider Provider weg. Die Speicherung der Daten steht mehr im Fokus, da auf die Daten maximal zwei mal zugegriffen werden. Die OneZone-IA fällt auch weg, da die Daten in nur einer Availability Zone gespeichert wird. Das Risiko für den Nicht-Zugriff der Daten durch der Nicht-Verfügbarkeit dieser Zone steigt dadurch. Daten müssen auf Abruf schnell zugreifbar sein, deshalb sind die OneZone-IA und die Coldline nicht geeignet, da sie eher für selten abgerufen Daten angepasst sind. Die Abrufkosten dieser Speicherklassen sind am höchsten und nicht zu empfehlen.

Insgesamt wird für die Persistenz von Binärdaten ein Object Storage mit den Speicherklassen Standard-IA von AWS und die Nearline von GC empfohlen. Sie bieten die nötigen Funktionen an, um die Anforderungen zu decken und kostengünstig Daten auf längerer Zeit zu speichern und dabei eine hohe Verfügbarkeit und eine schnelle Performance zu bieten. Die Präferenzen hängen auch mit der Entscheidung ab, was das Unternehmen braucht und präferiert. Beide Provider bieten eine gute Objektspeicherung kostengünstig und leistungsfähig an.

Bei der zweiten gestellten Frage geht es um die Bereitstellung der Daten durch signierte zeitlich begrenzte URLs. Diese Frage wurde durch Ausprobieren der SDKs beim Prototypen untersucht und bewertet. Es stellt sich heraus, dass beide Cloud Provider die Funktionen anbieten, signierte URLs zu erstellen und zeitlich bereitzustellen. Durch den Prototypen kann man Dateien hochladen und sie durch diese URLs bereitstellen. Durch Klicken auf den generierten Link werden die Daten heruntergeladen. So kann verhindert werden, Dateien nicht direkt in Email Anhängen hinzuzufügen und diese durch die Links bereitstellen zu können. Diese Dateien werden von den Buckets entschlüsselt heruntergeladen und Nutzer können ohne AWS oder GC Credentials darauf zugreifen. Diese URLs sind zeitlich begrenzt. Über den Prototypen kann man die Minuten, in der der Link valide ist, angeben. GC und AWS stellen ausführliche Dokumentationen auf den offiziellen Seiten bereit, um diese Funktionen zu implementieren und anzuwenden in verschiedenen Programmiersprachen.

So kann leoticket vom alten System zu der neuen empfohlenen Speicherlösung wechseln, um Daten sicher und schnell bereitzustellen und auf längerer Zeit zu speichern. Es ist zu beachten, dass diese Arbeit lediglich dem Vergleich und der Veranschaulichung beider Cloud Provider dient und das jedes Unternehmen unterschiedliche Anforderungen aufweist. Diese Arbeit dient als Stütze und zum Ausprobieren der Technologien durch den Prototypen.

6.2 Potenzielle Anwendung des Prototyps

Der Prototyp wurde dafür entwickelt, sich mit den Technologien der Cloud Provider auseinanderzusetzen und auszuprobieren. Durch die Anwendung konnten Performance Analysen durchgeführt werden, die zur Auswahl des Speichersystems beitragen. Die Anwendung kann noch ausgebaut werden, sodass es den Bedürfnissen der Unternehmen entspricht. Sie stellt eine Bibliothek dar, die in eigene Anwendungen integriert werden kann. Um sich mit den Technologien vertraut zu machen, können Dateien hoch-, und heruntergeladen werden. Außerdem ist es möglich durch Terraform Buckets mit den benötigten Einstellungen und Rechten zu erstellen ohne die Cloud Konsole verwenden zu müssen.

Der Prototyp wurde dabei an die Anforderungen von leoticket angelehnt und angepasst, damit es in das Software Produkt leoticket integriert werden kann. Es dient zur Hilfestellung für das Wechseln der alten Datenbank von Galera Cluster in ein neues Object Storage System.

7 Danksagung

8 Literaturverzeichnis

Internetquellen

- | | | |
|-----------------------|------|--|
| aws-availability | [1] | AWS: Data Protection in Amazon S3. Abgerufen am 14.05.2023. URL: https://docs.aws.amazon.com/AmazonS3/latest/userguide/DataDurability.html . |
| aws-iam-s3 | [2] | AWS: Security: Identity and Access Management. Abgerufen am 11.05.2023. URL: https://docs.aws.amazon.com/de_de/AmazonS3/latest/userguide//access-control-overview.html . |
| aws-sse-c | [3] | AWS: Using server-side encryption with customer-provided keys (SSE-C). Abgerufen am 12.05.2023. URL: https://docs.aws.amazon.com/AmazonS3/latest/userguide/ServerSideEncryptionCustomerKey.html . |
| gcp-sla | [4] | Google Cloud: Cloud Storage Service Level Agreement (SLA). Abgerufen am 17.05.2023. URL: https://cloud.google.com/storage/sla . |
| gcp-autoscale | [5] | Google Cloud: Request rate and access distribution guidelines: Auto Scaling. Abgerufen am 17.05.2023. URL: https://cloud.google.com/storage/docs/request-rate . |
| spring-cloud-announce | [6] | Spencer Gibb: Spring Cloud AWS 2.3 is now available. Abgerufen am 24.05.2023. URL: https://spring.io/blog/2021/03/17/spring-cloud-aws-2-3-is-now-available#why-has-the-package-name-changed . |
| ibm-storage | [7] | IBM: What is object storage? Abgerufen am 07.05.2023. URL: https://www.ibm.com/topics/object-storage . |
| dataCore-OS | [8] | Mike Ivanov: File Storage vs. Object Storage: Understanding Differences, Applications and Benefits, What is Object Storage? (2020). Abgerufen am 07.05.2023. URL: https://www.datacore.com/blog/file-object-storage-differences/ . |
| leomedia-web | [9] | GmbH Leomedia: Bachelor- und Master-Themen. URL: https://www.leomedia.de/unternehmen/abschlussarbeiten/ . |
| gcp-blog | [10] | Colt McAnlis: Optimizing your Cloud Storage performance: Google Cloud Performance Atlas. Abgerufen am 18.05.2023. URL: https://cloud.google.com/blog/products/gcp/optimizing-your-cloud-storage-performance-google-cloud-performance-atlas/ . |
| oracle-bigdata | [11] | Oracle: Was versteht man unter Big Data? URL: https://www.oracle.com/de/big-data/what-is-big-data/ . |
| redHat-storage | [12] | RedHat: File storage, block storage, or object storage? (2018). Abgerufen am 06.05.2023. URL: https://www.redhat.com/en/topics/data-storage/file-block-object-storage . |
| aws-api | [13] | Amazon S3: Amazon S3 REST API Introduction. Abgerufen am 18.05.2023. URL: https://docs.aws.amazon.com/AmazonS3/latest/API/Welcome.html . |
| aws-sdk | [14] | Amazon S3: Developing with Amazon S3 using the AWS SDKs, and explorers: Using this service with an AWS SDK. Abgerufen am 18.05.2023. URL: https://docs.aws.amazon.com/AmazonS3/latest/userguide/UsingAWSSDK.html . |
| performance-guide | [15] | Amazon S3: Performance Guidelines for Amazon S3. Abgerufen am 18.05.2023. URL: https://docs.aws.amazon.com/AmazonS3/latest/userguide/optimizing-performance-guidelines.html . |

- | | | |
|-----------------|------|--|
| aws-signed-urls | [16] | Amazon S3: Using presigned URLs. Abgerufen am 19.05.2023. URL: https://docs.aws.amazon.com/AmazonS3/latest/userguide/using-presigned-url.html . |
| gcp-encrypt | [17] | Google Cloud Storage: Google-managed encryption keys. Abgerufen am 13.05.2023. URL: https://cloud.google.com/storage/docs/encryption/default-keys . |
| gc-perfdiag | [18] | Google Cloud Storage: perfdiag - Run performance diagnostic. Abgerufen am 21.05.2023. URL: https://cloud.google.com/storage/docs/gsutil/commands/perfdiag . |
| nx-fileScala | [19] | Lauren Wahlman: Data Storage: Exploring File, Block, and Object Storage. (2022). Abgerufen am 06.05.2023. URL: https://www.nutanix.com/blog/block-storage-vs-object-storage-vs-file-storage . |

9 Anhang

9.1 Repositories

9.1.1 Github Link

Prototyp Repository:

HTTPS: <https://github.com/gmzbae/cloud-gcs-aws3.git>

SSH: `git clone git@github.com:gmzbae/cloud-gcs-aws3.git`

Thesis Repository:

HTTPS: <https://github.com/gmzbae/bachelor-thesis-latex.git>

SSH: `git clone git@github.com:gmzbae/bachelor-thesis-latex.git`

9.1.2 Dokumentation

Code Dokumentation

Entwickler Handbuch

9.1.3 Code Snippets